

IT 2569/NW14

รายงานฉบับสมบูรณ์

การจัดสรรช่องสัญญาณแบบไดนามิกในเครือข่าย Wi-Fi Mesh
โดยใช้เทคนิคการเรียนรู้แบบเสริมกำลังหลายตัวแทน

DYNAMIC CHANNEL ASSIGNMENT FOR WI-FI MESH NETWORKS
USING MULTI-AGENT REINFORCEMENT LEARNING

โดย

663380363-7 นายวิศรุต ไตรยวงศ์

อาจารย์ที่ปรึกษา: ศ.ดร.จักรชัย โสอินทร์

รายงานนี้เป็นส่วนหนึ่ง ของการศึกษารายวิชา SC364771 โครงงานทางเทคโนโลยีสารสนเทศ 1
ภาคการศึกษาที่ 1 ปีการศึกษา 2569
หลักสูตรเทคโนโลยีสารสนเทศ สาขาวิชาวิทยาการคอมพิวเตอร์
วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น
(เดือน พฤศจิกายน พ.ศ.2569)

นายวิศรุต ไตรยวงศ์ 2569. **การจัดสรรช่องสัญญาณแบบไดนามิกในเครือข่าย Wi-Fi Mesh โดยใช้เทคนิคการเรียนรู้แบบเสริมกำลังหลายตัวแทน.** โครงงานทางเทคโนโลยีสารสนเทศ 1. ปริญญาวิทยาศาสตรบัณฑิต หลักสูตรวิชาเทคโนโลยีสารสนเทศ สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.

อาจารย์ที่ปรึกษา: ศาสตราจารย์ ดร.จักรชัย โสอินทร์

บทคัดย่อ

โครงงานนี้ศึกษาการจัดสรรช่องสัญญาณแบบไดนามิกร่วมกับการเลือกเส้นทางในเครือข่าย Wi-Fi Mesh แบบหลาย hop และเสนอ EGAT-MAPPO ซึ่งให้แต่ละโหนดเป็นตัวแทนที่เลือกช่องสัญญาณ downlink และโหนดแม่ (parent) ของตนเอง แบบจำลองใช้ Graph Attention Network ที่รับคุณลักษณะของขอบ (edge-aware GATv2) หัวตัดสินใจสองช่วงเวลา และ residual prior จากวิธี local cost ของ Ko ฝึกด้วย behaviour cloning จาก Ko ตามด้วย MAPPO และเพิ่ม switch hysteresis ขณะใช้งานเพื่อลดการสลับที่ไม่จำเป็น การทำงานขณะใช้งานเป็นแบบกระจายศูนย์ โดยแต่ละโหนดใช้เฉพาะข้อมูลของตนและเพื่อนบ้าน

ประเมินบนสภาพแวดล้อมจำลอง Python ที่เขียนขึ้นเอง ใช้ PHY ของ 802.11ax และ path loss ตามค่าเริ่มต้นของ ns-3 เครือข่าย 20 โหนด 2 gateway และ 6 ช่อง downlink ใน 11 สถานการณ์ทดสอบ (S1–S6, B1–B5) เทียบกับ M0 (ช่องคงที่), Ko, Q-neutral, Yuan (GAT+DQN) และ Li (GAT-A2C) ทุกวิธีที่เรียนรู้ฝึก 5 ค่าเมล็ดสุ่ม และทดสอบบน 20 topology ต่อสถานการณ์ ใช้คะแนนรวม (composite) ห้าตัวชี้วัดที่กำหนดไว้ล่วงหน้า และช่วงความเชื่อมั่นที่นับความแปรปรวนของค่าเมล็ดสุ่มการฝึกของทั้งสองวิธี

แบบจำลอง airtime ของสภาพแวดล้อมจำลองปรับเทียบกับ ns-3 ระดับแพ็กเก็ต (ความคลาด rms 7.4%) ก่อนฝึกในสภาวะหลัก (setting a) บน topology ยืนยันชุดใหม่ (ค่าเมล็ดสุ่ม 40–59) ที่กำหนดไว้ก่อนรัน EGAT-MAPPO มีคะแนนรวมสูงกว่าคู่เทียบที่ดัดแปลงจากงานเผยแพร่ทุกวิธีเกิน 10% (Ko +24.6%, Li +17.9%, Yuan +24.8%) และผ่านเกณฑ์ที่กำหนดไว้ทั้ง 4 ข้อ ผลไปทางเดียวกันบน topology ทดสอบ บน topology ใหม่ชุดที่สอง และใน setting ที่เก็บคิวระหว่างสลับได้ เมื่อให้ Li และ Yuan ใช้ switch hysteresis แบบเดียวกัน EGAT-MAPPO ยังดีกว่าอย่างมีนัยสำคัญ (Li+H +10.7%, Yuan+H +6.7%) บน topology ทดสอบ throughput สูงกว่า Ko 12.4% และสลับน้อยกว่า 93% (42 เทียบ 616 ครั้งต่อ episode) บน ns-3 ใน 3 สถานการณ์ EGAT-MAPPO ดีกว่าทุกวิธีอย่างมีนัยสำคัญ ทั้งแบบใช้และไม่ใช้ RTS/CTS (Ko +23.1%, Yuan+H +16.4%) รุ่นสุดท้ายนี้ตัดหน่วยความจำ GRU ออกตามผลการตัดองค์ประกอบ และยืนยันด้วยโปรโตคอลที่กำหนดไว้ก่อนรันบน topology ที่ไม่เคยใช้

คำสำคัญ: การจัดสรรช่องสัญญาณ การเลือกเส้นทาง Wi-Fi Mesh Graph Attention Network MAPPO การเรียนรู้แบบเสริมกำลังหลายตัวแทน

Mr.Wissarut Taiyawong 2569. **Dynamic Channel Assignment for Wi-Fi Mesh Networks Using Multi-Agent Reinforcement Learning.** Project in Information Technology I. Bachelor of Science in Information Technology, College of Computing, Khon Kaen University.

Project Advisor: Prof. Chakchai So-In, Ph.D.

ABSTRACT

This project studies joint dynamic channel assignment and routing in multi-hop Wi-Fi mesh networks. We propose EGAT-MAPPO, in which every node is an agent that chooses its downlink channel and its parent. The model combines an edge-aware graph attention encoder (GATv2), two decision timescales and a residual prior from Ko's local-cost rule. It is warm-started by behaviour cloning from Ko, trained with MAPPO, and executed in a decentralised way with switch hysteresis that suppresses unnecessary switches.

We evaluate it in a custom Python simulator with an 802.11ax PHY and ns-3 default path loss: 20 nodes, two gateways and six downlink channels, across 11 scenarios. The baselines are a static assignment (M0), Ko, Q-neutral, Yuan (GAT+DQN) and Li (GAT-A2C). Every learned method is trained with five seeds and tested on 20 topologies per scenario. We use a pre-registered five-metric composite and intervals that count the training-seed variance of both methods.

The simulator's airtime model is calibrated against packet-level ns-3 (7.4% rms error) before training. In the main setting, on a pre-registered set of fresh confirmation topologies (seeds 40-59), EGAT-MAPPO's composite exceeds every adapted published baseline by more than 10% (Ko +24.6%, Li +17.9%, Yuan +24.8%) and all four pre-registered criteria are met; the test topologies, a second fresh set and queue-preserving switches give the same picture. When Li and Yuan receive the same switch hysteresis, EGAT-MAPPO still beats both significantly (Li with hysteresis +10.7%, Yuan with hysteresis +6.7%). On the test topologies its throughput is 12.4% above Ko's with 93% fewer switches (42 versus 616 per episode). In ns-3 on three scenarios it significantly beats every method with and without RTS/CTS (Ko +23.1%, Yuan with hysteresis +16.4%). The final model drops the GRU memory after the ablation study, a change confirmed under a protocol fixed before the confirmation run on unused topologies.

Keywords: Channel assignment, Routing, Wi-Fi mesh, Graph attention network, MAPPO, Multi-agent reinforcement learning

กิตติกรรมประกาศ

โครงงานฉบับนี้ดำเนินงานตามวัตถุประสงค์ที่กำหนดไว้ โดยได้รับคำแนะนำด้าน wireless networking และ machine learning จากอาจารย์ที่ปรึกษา คำแนะนำดังกล่าวมีส่วนสำคัญต่อการออกแบบการทดลองและการปรับปรุงเนื้อหาในรายงาน

ขอขอบพระคุณคณะกรรมการสอบโครงงานทุกท่านสำหรับเวลาและข้อเสนอแนะที่ช่วยให้รายงานมีความถูกต้องและเป็นระบบมากขึ้น

ขอขอบพระคุณคณาจารย์ประจำหลักสูตรเทคโนโลยีสารสนเทศ สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น สำหรับความรู้และคำแนะนำตลอดระยะเวลาการศึกษา

ขอขอบพระคุณบิดา มารดา และครอบครัวสำหรับการสนับสนุนตลอดระยะเวลาการจัดทำโครงงาน

ขอขอบคุณเพื่อนนักศึกษาทุกคนสำหรับกำลังใจและความช่วยเหลือระหว่างการทำโครงงาน

ผู้จัดทำ

วิศรุต ไตรยวงศ์

สารบัญ

	หน้า
บทคัดย่อ	ก
ABSTRACT	ข
กิตติกรรมประกาศ	ค
สารบัญตาราง	ฉ
สารบัญภาพ	ช
บทที่ 1 บทนำ	1
1.1 ความเป็นมาและความสำคัญของปัญหา	1
1.2 วัตถุประสงค์	1
1.3 เป้าหมายและขอบเขต	2
1.4 ประโยชน์ที่คาดว่าจะได้รับ	2
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	3
2.1 ทฤษฎีที่เกี่ยวข้อง	3
2.2 งานวิจัยที่เกี่ยวข้อง	5
บทที่ 3 วิธีการดำเนินงาน	13
3.1 เครื่องมือที่ใช้ในการดำเนินงาน	13
3.2 ขั้นตอนการดำเนินงาน	13
3.3 แผนและระยะเวลาการดำเนินงาน	15
3.4 วิธีประเมินผล	17
บทที่ 4 การวิเคราะห์ระบบและผลการทดลอง	18
4.1 การกำหนดรูปแบบของปัญหาและแบบจำลองระบบ	20
4.2 การออกแบบสถาปัตยกรรมของ EGAT-MAPPO	21
4.3 สภาพแวดล้อมการทดลองและการกำหนดพารามิเตอร์	22
4.4 ผลการทดลองหลัก	24
4.5 ผลใน setting ที่เก็บคิวระหว่างสลับ (b)	32
4.6 การปรับเทียบและยืนยันผลบน ns-3	33
4.7 ผลระยะที่ 1: GAT+RAES บน native ns-3 แบบ single-hop	35
บทที่ 5 บทสรุป	36
5.1 สรุปผลการดำเนินโครงงาน	36

สารบัญ (ต่อ)

	หน้า
5.2 ข้อจำกัดของระบบ	36
5.3 ปัญหาอุปสรรคและแนวทางแก้ไข	38
5.4 ข้อเสนอแนะในการพัฒนา	38
เอกสารอ้างอิง	39
ประวัติผู้เขียน	42

สารบัญตาราง

	หน้า
ตารางที่ 1 ตารางเปรียบเทียบงานวิจัย	8
ตารางที่ 2 แผนการดำเนินงานโครงงาน GAT–MARL และการตรวจสอบด้วย ns-3	15
ตารางที่ 3 พารามิเตอร์ของสภาพแวดล้อมจำลอง	23
ตารางที่ 4 ค่าพารามิเตอร์ของ EGAT-MAPPO	23
ตารางที่ 5 สถานการณ์ทดสอบ (ภาระเฉลี่ย 6 Mb/s ต่อโหนด n = 20 และ 2 gateway ถ้าไม่ระบุ)	23
ตารางที่ 6 คะแนนรวมของ EGAT+H เทียบคู่เทียบ (setting a, A+B, ค่าเมล็ดสุ่มทดสอบ 0–19)	25
ตารางที่ 7 ส่วนของคะแนนรวมจากแต่ละตัวชี้วัด (setting a, A+B, ค่าเมล็ดสุ่ม 0–19)	27
ตารางที่ 8 ค่าเฉลี่ยของตัวชี้วัด และคะแนนรวมที่ EGAT+H ดีกว่าแต่ละวิธี (setting a, A+B, ค่าเมล็ดสุ่ม 0–19)	28
ตารางที่ 9 EGAT+H เทียบคู่เทียบที่มี hysteresis (setting a, A+B, ค่าเมล็ดสุ่ม 0–19)	29
ตารางที่ 10 EGAT+H บน topology ใหม่ (setting a, A+B, ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม [95% CI])	30
ตารางที่ 11 การตัดองค์ประกอบของแบบที่มี GRU (setting a, A+B, 3 ค่าเมล็ดสุ่มต่อแบบ, ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม)	31
ตารางที่ 12 ผลตามเกณฑ์ที่กำหนดไว้ แยกตาม setting และชุด topology (เทียบคู่เทียบที่ดัดแปลงจากงานเผยแพร่)	33
ตารางที่ 13 คะแนนรวมของ EGAT+H เทียบคู่เทียบ บนสภาพแวดล้อมจำลองและ ns-3 (setting a, S2/B1/B3, ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม [95% CI])	34
ตารางที่ 14 ผลหลักของหกวิธีในระยะที่ 1 (native ns-3, single-hop) พร้อม Normal อ้างอิง	35

สารบัญภาพ

	หน้า
ภาพที่ 1 สถาปัตยกรรมของ EGAT-MAPPO (**σ** คือ LeakyReLU, กล่องสีส้มคือส่วนที่มาจาก Ko, กล่องสีเขียวและเส้นประใช้เฉพาะตอนฝึก)	21
ภาพที่ 2 คะแนนรวมของ EGAT+H เทียบคู่เทียบ พร้อมช่วงความเชื่อมั่น 95% บน topology ทดสอบ 0–19 topology ใหม่ 20–39 และ topology ยืนยัน 40–59 (เส้นประคือเป้าหมาย +10%)	26
ภาพที่ 3 Throughput รวมเทียบจำนวนการสลับต่อ episode (สเกล log) ของแต่ละวิธี เฉลี่ย A+B setting (a) topology 0–19 แกน y ไม่ได้เริ่มที่ 0	29
ภาพที่ 4 คะแนนรวมของ EGAT+H เทียบ Ko รายสถานการณ์ ใน setting (a) และ (b) (เส้นประคือขอบเขต −5% ของเกณฑ์ข้อ 3)	32

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

เครือข่าย Wi-Fi Mesh [1] ช่วยขยายพื้นที่ให้บริการในระบบขนาดกลางถึงขนาดใหญ่โดยไม่ต้องพึ่งศูนย์กลางเพียงจุดเดียว แต่การใช้งานอุปกรณ์จำนวนมากในพื้นที่เดียวกันทำให้เกิด Channel Interference [4] ส่งผลให้ความเร็วการเชื่อมต่อและเสถียรภาพของเครือข่ายลดลง

แนวทางหนึ่งคือใช้ Multi-Agent Reinforcement Learning (MARL) [3] ให้แต่ละ node เลือกช่องสัญญาณจากข้อมูลของตนเองโดยไม่ต้องพึ่งศูนย์กลาง Agent จะเลือก action และรับ reward จาก environment ที่เปลี่ยนแปลง ทำให้ policy ปรับตามสถานการณ์ได้ดี

โครงงานแบ่งเป็นสองระยะ ระยะที่ 1 พัฒนา GAT+RAES และรุ่น Hybrid แล้วประเมินด้วย native ns-3 บน 15 คู่ AP–STA แบบ single-hop และ 4 ช่อง ผลระยะนี้ยังไม่ครอบคลุม relay หรือ routing หลาย hop ซึ่งเป็นลักษณะสำคัญของ Wi-Fi Mesh ระยะที่ 2 จึงพัฒนา EGAT-MAPPO สำหรับเครือข่าย mesh หลาย hop ที่ให้แต่ละโหนดตัดสินใจทั้งช่องสัญญาณและเส้นทางร่วมกัน และประเมินเทียบกับคู่เทียบจากงานเผยแพร่ภายใต้โปรโตคอลที่กำหนดไว้ล่วงหน้า ผลหลักของรายงานฉบับนี้มาจากระยะที่ 2 ส่วนผลระยะที่ 1 สรุปไว้ในหัวข้อ 4.7

1.2 วัตถุประสงค์

1.2.1 เพื่อกำหนดแบบจำลองระบบ ปริภูมิสถานะ การกระทำ และผลตอบแทน สำหรับการจัดสรรช่องสัญญาณร่วมกับการเลือกเส้นทางในเครือข่าย Wi-Fi Mesh แบบหลาย hop โดยให้ทุกโหนดตัดสินใจจากข้อมูลของตนและเพื่อนบ้าน

1.2.2 เพื่อพัฒนา EGAT-MAPPO ที่ผสาน Graph Attention Network แบบรับคุณลักษณะของขอบ การเรียนรู้แบบ MAPPO และความรู้จาก heuristic ของ Ko พร้อมกลไกลดการสลับช่องและเส้นทางขณะใช้งาน

1.2.3 เพื่อเปรียบเทียบ EGAT-MAPPO กับ M0, Ko, Q-neutral, Yuan และ Li ด้วยคะแนนรวมห้าตัวชี้วัดที่กำหนดไว้ล่วงหน้า (throughput รวม, Jain fairness, throughput เปอร์เซ็นไทล์ที่ 5, อัตราสูญเสีย และจำนวนการสลับ) และการทดสอบทางสถิติที่นับความแปรปรวนจากการฝึก

1.2.4 เพื่อวิเคราะห์ที่มาของผลที่ได้ ทั้งด้วยการแยกคะแนนรายตัวชี้วัด การให้คู่เทียบใช้กลไกลดการสลับแบบเดียวกัน และการตัดองค์ประกอบของแบบจำลองทีละส่วน

1.3 เป้าหมายและขอบเขต

1.3.1 เป้าหมายของโครงงาน

(1) ได้แบบจำลองที่ดีกว่าคู่เทียบทุกวิธีอย่างน้อย 10% ตามคะแนนรวมที่กำหนดไว้ อย่างมีนัยสำคัญทางสถิติ และไม่แย่กว่า Ko เกิน 5% ในสถานการณ์ใด

(2) การทำงานขณะใช้งานเป็นแบบกระจายศูนย์ แต่ละโหนดใช้เฉพาะ observation ของตนและเพื่อนบ้าน ส่วน critic ส่วนกลางใช้เฉพาะตอนฝึก

(3) รายงานผลอย่างโปร่งใส ทั้งกรณีที่ชนะ กรณีที่ส่วนต่างลดลงเมื่อคู่เทียบได้รับกลไกเดียวกัน และกรณีที่ยังแพ้

1.3.2 ขอบเขตของโครงงาน

(1) ด้านสภาพแวดล้อมจำลอง ผลหลักมาจากสภาพแวดล้อม Python ที่เขียนขึ้นเอง ระดับ flow (fluid model) ใช้ PHY ของ 802.11ax และ path loss ตามค่าเริ่มต้นของ ns-3 แบบจำลอง airtime ปรับเทียบกับ ns-3 แบบระดับแพ็กเก็ต และยืนยันผลหลักบน ns-3 ใน 3 สถานการณ์ แต่ยังไม่ได้ทดสอบบนอุปกรณ์จริง

(2) ด้านพารามิเตอร์เครือข่าย ฝึกบนเครือข่าย 20 โหนด 2 gateway แต่ละโหนดมี 2 วิทยุ เลือกช่อง downlink ได้ 6 ช่อง และเลือกโหนดแม่ได้ 4 ตัวเลือก ทดสอบเพิ่มที่ 50 และ 80 โหนด และ 4 gateway

(3) ด้านเทคนิคการเรียนรู้ ใช้ Multi-Agent Reinforcement Learning แบบ centralized training with decentralized execution ด้วย MAPPO โดยใช้พารามิเตอร์ร่วมกันทุกโหนด

(4) ด้านการเปรียบเทียบผล คู่เทียบคือ M0, Ko [19], Q-neutral, Yuan [20] และ Li [21] ซึ่งดัดแปลงให้ใช้ observation, action, รูปแบบ reward และงบการฝึกเดียวกัน และบันทึกการดัดแปลงทุกจุด ความต่างเดียวด้าน reward คือ EGAT-MAPPO ปรับน้ำหนัก λ ระหว่างฝึก (หัวข้อ 4.1.4)

(5) ด้านตัวชี้วัด ใช้คะแนนรวมห้าตัวชี้วัดและเกณฑ์ความสำเร็จ 4 ข้อที่กำหนดไว้ก่อนการทดลองหลัก การเปลี่ยนแปลงหลังเห็นผลทุกครั้งบันทึกพร้อมวันที่ (รายละเอียดในหัวข้อ 3.4) และยืนยันด้วยชุด topology ใหม่

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1.4.1 ได้แบบจำลองต้นแบบสำหรับจัดสรรช่องสัญญาณร่วมกับการเลือกเส้นทางในเครือข่าย Wi-Fi Mesh แบบหลาย hop ที่ทำงานแบบกระจายศูนย์

1.4.2 ได้หลักฐานเชิงปริมาณว่าองค์ประกอบใดของแบบจำลองมีส่วนต่อผล และส่วนใดของผลมาจากการลดการสลับ ซึ่งนำไปใช้กับวิธีอื่นได้

1.4.3 ได้ฐานโค้ด สภาพแวดล้อมจำลอง และโปรโตคอลการประเมินที่ทำซ้ำได้ สำหรับขยายไปสู่การปรับเทียบกับ ns-3 และอุปกรณ์จริง

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 Wi-Fi Mesh Networks (เครือข่ายตาข่าย Wi-Fi)

เครือข่ายตาข่ายไร้สาย (Wireless Mesh Network: WMN) คือโครงสร้างเครือข่ายที่ประกอบด้วยจุดเชื่อมต่อ (Access Points: APs) หรือโหนดหลายตัวเชื่อมต่อกันแบบ peer-to-peer โดยแต่ละโหนดสามารถทำหน้าที่ทั้งรับ ส่ง และกระจายข้อมูลไปยังโหนดอื่น ๆ ได้ ทำให้เครือข่ายมีความทนทานสูง (self-healing) และสามารถ reroute ได้เมื่อโหนดใดโหนดหนึ่งล้มเหลว ข้อดีของเครือข่ายชนิดนี้คือสามารถครอบคลุมพื้นที่ขนาดใหญ่ได้โดยไม่จำเป็นต้องเดินสายทั้งหมด แต่ก็มีข้อจำกัดคือความซับซ้อนในการจัดการช่องสัญญาณ การควบคุม topology และปัญหาความหน่วง (latency) ที่เพิ่มขึ้นเมื่อจำนวน hop มากขึ้น [1]

2.1.2 Dynamic Channel Assignment (การจัดสรรช่องสัญญาณแบบไดนามิก)

Dynamic Channel Assignment (DCA) หรือ Dynamic Channel Allocation คือกลไกที่ไม่ได้จองช่องสัญญาณไว้ล่วงหน้าให้แต่ละโหนด (เช่น สถานีฐานในเครือข่ายเซลลูลาร์หรือ Wireless LAN) แต่จะจัดสรรช่องแบบไดนามิก ตามความต้องการ ณ ขณะนั้น เมื่อมีการร้องขอการใช้งาน เช่นวางการสื่อสาร หรือมีการเปลี่ยนแปลงของทราฟฟิกหรือสภาพแวดล้อมระบบ ไดนามิกแชแนลแอสไซน์เมนต์จะเลือกช่องสัญญาณที่เหมาะสมที่สุดตามอัลกอริทึมที่ประเมินตัวแปรต่าง ๆ เช่นอะไรที่จะลด interference, blocking probability, และปรับ frequency reuse ให้อัตโนมัติ ประหยัดทรัพยากรความถี่ และรองรับความเปลี่ยนแปลงของทราฟฟิกได้ดีกว่า Fixed Channel Allocation ที่จองช่องแบบถาวรใน [2]

2.1.3 Multi-Agent Reinforcement Learning (MARL)

MARL เป็นการต่อยอดจาก Reinforcement Learning (RL) ที่มีหลาย agent เรียนรู้ร่วมกันใน environment เดียวกัน แต่ละ agent เลือก action ตาม policy และรับ reward จาก action นั้น จึงประสานการตัดสินใจได้โดยไม่ต้องใช้ศูนย์กลาง แนวคิดนี้เหมาะกับ Wi-Fi Mesh ที่มี node กระจายหลายจุด [3]

2.1.4 Channel Interference (CI)

การชนกันของช่องสัญญาณเกิดขึ้นเมื่ออุปกรณ์ไร้สายหลายตัวใช้ช่องความถี่เดียวกันหรือใกล้กันมากเกินไป ส่งผลให้เกิดการรบกวนที่ลด Throughput เพิ่ม Latency และทำให้ Packet Loss สูงขึ้น สาเหตุหลักมาจากการกำหนดช่องสัญญาณแบบคงที่ การมีโหนดหนาแน่นในพื้นที่จำกัด และการรบกวนจากอุปกรณ์อื่น การแก้ปัญหานี้ต้องใช้วิธีจัดสรรช่องสัญญาณแบบไดนามิกที่สามารถปรับตามสภาพแวดล้อมแบบเรียลไทม์ [4]

2.1.5 การเรียนรู้แบบเสริมกำลัง (Reinforcement Learning - RL) และ Q-Learning

Reinforcement Learning (RL) ให้ Agent เรียนรู้การตัดสินใจจากการโต้ตอบกับ Environment เพื่อเพิ่ม cumulative Reward งานระยะที่ 1 ประยุกต์ใช้ Q-learning แบบ Value-based กับ Access Point (ส่วนระยะที่ 2 ใช้ policy gradient แบบ MAPPO ในหัวข้อ 2.1.8) โดยให้แต่ละ node เรียนรู้ Q-value ของแต่ละ Action ในแต่ละ State เมื่อ action เพิ่ม Throughput จะได้ reward เชิงบวก; เมื่อเกิด Interference จะได้รับ penalty การลองผิดลองถูกทำให้ node ปรับน้ำหนักเครือข่ายและสร้าง Policy สำหรับ channel assignment ได้เอง [5]

2.1.6 โครงข่ายประสาทแบบกราฟ (Graph Neural Networks - GNN)

โครงข่ายประสาทแบบกราฟ (Graph Neural Networks หรือ GNN) เป็นสถาปัตยกรรมการเรียนรู้เชิงลึกที่ออกแบบมาเพื่อประมวลผลข้อมูลที่มีโครงสร้างความสัมพันธ์แบบกราฟ ซึ่งประกอบด้วยโหนด (Node) และเส้นเชื่อม (Edge) สำหรับโครงงานนี้ โครงสร้างของเครือข่าย Wi-Fi Mesh จะถูกแปลงเป็นกราฟโดยให้จุดเชื่อมต่อเป็นโหนด และระยะการรบกวนของสัญญาณเป็นเส้นเชื่อม GNN จะนำมาใช้เพื่อแก้ข้อจำกัดด้านการรับรู้ข้อมูลที่ไม่สมบูรณ์ (Partial Observability) ในระบบหลายตัวแทน ผ่านกลไกการส่งผ่านข้อความ (Message Passing) ที่เปิดโอกาสให้แต่ละโหนดสามารถดึงข้อมูลสถานะจากเพื่อนบ้านข้างเคียงมาประมวลผลรวมกับข้อมูลของตนเองได้ การสกัดคุณลักษณะเชิงพื้นที่ (Spatial Feature Extraction) เช่นนี้ ทำให้ตัวแทนมีความตระหนักรู้ถึงโครงสร้างของเครือข่าย (Topology Awareness) อย่างลึกซึ้ง ซึ่งช่วยแก้ปัญหาพฤติกรรมการแห่ตามกัน (Herd Behavior) และทำให้ระบบสามารถตัดสินใจหลบหลีกการชนกันของคลื่นความถี่ได้อย่างแม่นยำยิ่งขึ้น[6]

2.1.7 Graph Attention Network รุ่น GATv2 และคุณลักษณะของขอบ

Graph Attention Network (GAT) [22] ให้แต่ละโหนดรวมข้อมูลจากเพื่อนบ้านด้วยน้ำหนักความสนใจที่เรียนได้ GATv2 [23] แก้ข้อจำกัดของ GAT เดิมที่ลำดับความสำคัญของเพื่อนบ้านไม่ขึ้นกับโหนดผู้ถาม โดยใส่ฟังก์ชันไม่เชิงเส้นก่อนคูณกับเวกเตอร์ความสนใจ ในเครือข่ายไร้สาย ความสัมพันธ์ระหว่างโหนดขึ้นกับลิงก์ เช่น SNR อัตราส่งข้อมูล และภาระของลิงก์ โครงงานนี้จึงเพิ่มคุณลักษณะของขอบเข้าไปในคะแนนความสนใจ

2.1.8 Proximal Policy Optimization และ MAPPO

Proximal Policy Optimization (PPO) [24] เป็นวิธี policy gradient ที่จำกัดขนาดการปรับนโยบายในแต่ละรอบด้วยการตัด (clip) อัตราส่วนความน่าจะเป็น ทำให้การฝึกเสถียร และมักใช้ร่วมกับ Generalized Advantage Estimation (GAE) [25] MAPPO [26] ขยาย PPO ไปสู่หลายตัวแทนแบบ centralized training with decentralized execution โดยให้ตัวแทนใช้ actor ร่วมกัน และใช้ critic ที่เห็นข้อมูลภาพรวมเฉพาะตอนฝึก งานของ Yu และคณะ [26] แสดงว่า MAPPO ทำได้ดีในเกมร่วมมือหลายแบบ

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 Adaptive Channel Assignment for Wireless Mesh Networks Based on Multi-Intelligent BodyRL

งานวิจัยนี้นำเสนออัลกอริทึมการจัดสรรช่องสัญญาณแบบปรับตัวได้สำหรับเครือข่าย Wi-Fi Mesh โดยใช้การเรียนรู้แบบเสริมกำลังหลายตัวแทน (MARL) เพื่อแก้ปัญหาการจัดสรรช่องสัญญาณแบบคงที่ที่ไม่สามารถปรับตัวตามทราฟฟิกได้ งานนี้ใช้โครงสร้างแบบ CTDE ผ่านอัลกอริทึม MADDPG โดยให้แต่ละโหนดตัดสินใจจากข้อมูลท้องถิ่น (Local Observation) เพื่อลดสัญญาณรบกวน ผลการจำลองผลชี้ว่าระบบสามารถเรียนรู้และปรับปรุงคุณภาพการสื่อสารได้ดีกว่าการสุ่ม แต่ ข้อจำกัดของงานนี้คือตัวแทนไม่มีการรับรู้โครงสร้างเครือข่ายโดยรวม (Topology Awareness) ทำให้เมื่อเกิดความหนาแน่นสูง อาจเกิดปัญหาพฤติกรรมแห่ตามกัน (Herd Behavior) จนช่องสัญญาณชนกันได้ [7]

2.2.2 Channel Selection for Wi-Fi 7 MLO

งานนี้มุ่งแก้ปัญหาการเลือกช่องในระบบ Wi-Fi 7 Multi-Link Operation (MLO) โดยเสนอ MARL ในรูปแบบ Parallel Transfer RL ผสมกับ Value Decomposition Networks (VDN) ชื่อ VDN ใช้ตัวแทนหลายตัวเรียนรู้เชิงรุกแบบสหกรณ์ (cooperative) บนเครือข่าย MLO โดยทดสอบหลายวิธีแลกเปลี่ยนประสบการณ์การเรียนรู้ระหว่างระบบย่อย ผลลัพธ์แสดงว่าเวอร์ชัน Optimistic (oVDNg ที่ใช้ประสบการณ์ดีที่สุด) ทำงานได้ดีที่สุด โดยให้ผลตอบแทนสูงกว่าวิธีพื้นฐาน (VDN ปกติ) ราว 3–11% และเร่งการหาผลลัพธ์ดีขึ้นมากเร็วขึ้น ~ 135% และรวดเร็วขึ้น ~ 40 episodes ข้อจำกัดคือทดสอบผ่านการจำลองเท่านั้น อาจยังต้องทดสอบในสถานการณ์จริง และยังไม่เปรียบเทียบกับวิธี MARL อื่นๆ ชัดเจน [8]

2.2.3 Learning-Based Algorithms for Channel Allocations in Wireless Mesh Network

งานวิจัยนี้นำเสนอแนวทางการใช้การเรียนรู้ของเครื่องเพื่อจัดสรรช่องสัญญาณสำหรับลิงก์ (Backhaul Links) ในเครือข่าย WMN โดยเสนออัลกอริทึม 2 รูปแบบ ได้แก่ Spatial Adaptive Play (SAP) และ Multi-Agent Reinforcement Learning (MARL) เพื่อแก้ปัญหาของวิธีทฤษฎีเกม (Game-theoretic) ดั้งเดิมที่มักจะใช้ทรัพยากรช่องสัญญาณไม่คุ้มค่า ผลการจำลองพบว่าวิธีการที่อิงตามการเรียนรู้ช่วยเพิ่มจำนวนลิงก์ที่สามารถสื่อสารได้สำเร็จหลังจากการจัดสรรช่องสัญญาณอย่างมีนัยสำคัญ ข้อจำกัดคืออัลกอริทึมดังกล่าวยังไม่ได้ผนวกโครงสร้างความสัมพันธ์เชิงพื้นที่แบบซับซ้อน (Graph Structure) เข้าไปช่วยประกอบการตัดสินใจของตัวแทน [9]

2.2.4 QLBT: MARL for Distributed Channel Access

งานนี้นำเสนอโปรโตคอล MAC ใหม่ชื่อ QLBT (QMIX-advanced Listen-Before-Talk) เพื่อจัดการการเข้าถึงช่องสัญญาณแบบกระจาย ด้วย MARL (ปรับปรุงจากอัลกอริทึม QMIX) บนพื้นฐาน CTDE เพิ่มค่า Q ส่วนบุคคลของแต่ละตัวแทนใน mixing network เพื่อความเสถียร และนำเสนอการนำ delay ของการส่งครั้งสุดท้าย (D2LT) มาเป็นส่วนหนึ่งของสถานะของตัวแทน ช่วยให้ระบบเรียนรู้จัดลำดับความสำคัญของตัวที่ส่งมานานน้อยที่สุด ผลการจำลองแสดงว่า QLBT สามารถ ทำงานเหนือกว่า CSMA/CA แบบเดิมในสถานการณ์ต่างๆ ทั้งความหนาแน่นทราฟฟิกสูง ต่ำ และงานที่ไวต่อเวลา และยังทำงานได้ทนทานต่อการเปลี่ยนแปลงสภาพแวดล้อม และสามารถทำงานร่วมกับอุปกรณ์ CSMA/CA แบบเดิมได้ด้วย ข้อจำกัดของงานนี้คือเป็นงานวิจัยทางทฤษฎีที่ทดสอบในซิมูเลชัน การนำไปใช้จริงยังต้องพิจารณาด้านต้นทุนคอมพิวเตอร์และการวัดผลในเครือข่ายจริงเพิ่มเติม [10]

2.2.5 MACRL for Dynamic Topology

งานนี้นำเสนอ MACRL (Multi-Agent Actor-Critic RL) เพื่อแก้ปัญหาการเพิ่มขยายเครือข่ายไร้สายแบบ mesh โดยเน้นวัตถุประสงค์หลายตัวคือ ลดค่า End-to-End Delay และเพิ่มประสิทธิภาพการใช้ช่องสัญญาณ (channel efficiency) ออกแบบเป็น CTDE (central critic, distributed actors) โดยตัวประมาณค่า centralized critic มีข้อมูลเครือข่ายทั้งหมด ในขณะที่แต่ละตัวกระทำเรียนรู้แบบอิสระ ผลการทดสอบใน QaulNet (จำลองเครือข่ายจริง) ผลชี้ว่าระบบ MACRL นี้ช่วยลด latency และเพิ่มสัดส่วนช่องว่าง (idle channel) ได้ดีกว่าวิธีอื่นๆ แม้ว่าจะต้องปรับสมดุลรางวัลระหว่าง delay กับ throughput ข้อจำกัด เน้นเฉพาะการขยายเครือข่าย เพิ่ม AP, hops โดยยังไม่ได้พูดถึงประเด็นเช่น overhead หรือ scalability เมื่อจำนวนตัวแทนเพิ่มขึ้นมากๆ [11]

2.2.6 Heterogeneous MARL for WLAN Access

งานนี้ศึกษา heterogeneous MARL สำหรับ distributed channel access ใน Wi-Fi/WLAN โดยให้ agent ใช้ value-based หรือ policy-based learning ปะปนกันในกรอบ QPMIX และใช้ CTDE เพื่อรวมค่าของ agent เป้าหมายคือเพิ่ม average throughput และ fairness ผลจำลองรายงานว่า QPMIX ลด delay/jitter และ collision เมื่อเทียบกับ CSMA/CA โดยเฉพาะในสภาวะโหลดสูง ข้อจำกัดคือยังทดสอบเฉพาะ simulation ไม่รายงานตัวเลขเฉพาะ และไม่วิเคราะห์ training overhead [12]

2.2.7 Channel Management in WLANs

งานนี้เปรียบเทียบวิธีจัดการช่องสัญญาณแบบเรียลไทม์ใน WLAN ระหว่างวิธี heuristic กับ Deep RL โดยเสนอโมเดล DRL ชื่อ net2seq (policy-based actor-critic) กับอัลกอริทึม heuristic แบบใหม่ (dynLS, TurboCA) สำหรับปัญหา channel allocation แบบหลาย AP งานนี้ทดลองทั้งในซิมูเลชันและเครือข่ายจริง (34 AP) ผลพบว่า DRL สามารถค้นหานโยบายจัดสรรช่องที่ดีภายในเวลาจำกัด ได้ผลลัพธ์ เหนือกว่า heuristic แบบเดิมโดยเฉพาะในเครือข่ายขนาดใหญ่ และยัง generalize ไปใช้กับจำนวนโหนดที่มากขึ้นโดยประสิทธิภาพไม่ตก และยังทดลองบนเครือข่ายจริงเพื่อยืนยันผล โดยพบว่า DRL ให้ประสิทธิภาพสูงกว่า heuristics ในเชิง throughput แม้จะใช้ทรัพยากรคำนวณเพิ่มมากขึ้น ข้อจำกัดคือวิธี net2seq ต้องอาศัยการเรียนรู้เบื้องต้น (training) และอาจไม่ทันทีหากสภาพแวดล้อมเปลี่ยนแปลงรวดเร็ว การออกแบบ state/action สำหรับ DRL ยังเป็นเรื่องท้าทายในเครือข่ายขนาดใหญ่มากๆ ด้วย [13]

2.2.8 GAT-based MARL for Slicing Resource Management

งานวิจัยนี้นำโครงข่ายประสาทแบบกราฟเชิงความสนใจ (Graph Attention Network: GAT) มาวางไว้ที่ส่วนรับข้อมูลของอัลกอริทึม DQN และ A2C เพื่อเสริมความร่วมมือเชิงพื้นที่และเวลาระหว่างสถานีฐานในเครือข่ายเซลลูลาร์หนาแน่น โดยแต่ละสถานีฐานทำหน้าที่เป็นตัวแทนหนึ่งตัว จุดเด่นคือการพิสูจน์ว่ากลไก GAT สามารถยกระดับประสิทธิภาพของการเรียนรู้แบบเสริมกำลังเชิงลึกได้ในลักษณะทั่วไป กล่าวคือใช้ได้ทั้งกับอัลกอริทึมประเภทประเมินมูลค่า (Value-based) และประเภทผู้กระทำ-ผู้วิจารณ์ (Actor-critic) ผลการทดลองรายงานว่าที่ระดับความละเอียดหยาบ GAT-DQN ให้ผลตอบแทนระบบสูงกว่า DQN เดิมร้อยละ 4 และ GAT-A2C สูงกว่า A2C เดิมร้อยละ 5 ส่วนที่ระดับความละเอียดสูงซึ่งมีปริภูมิการกระทำใหญ่ขึ้น ทั้งสองอัลกอริทึมให้ผลดีขึ้นร้อยละ 7 และยังมีการศึกษาแบบตัดองค์ประกอบ (Ablation Study) ยืนยันว่า GAT ช่วยเพิ่มประสิทธิภาพการใช้คลื่นความถี่โดยไม่ลดอัตราความสำเร็จตามข้อตกลงระดับบริการ ข้อจำกัดคือโดเมนของงานเป็นการจัดสรรทรัพยากรแบบแบ่งส่วนเครือข่ายในระบบเซลลูลาร์ 5G มิใช่การจัดสรรช่องสัญญาณในเครือข่าย Wi-Fi Mesh และยังไม่ได้ระบุเทคนิคจัดการความไม่เสถียรของกลไกความสนใจในช่วงต้นของการฝึกสอน [14]

2.2.9 GA-Net: MARL for 6G in-X Subnetworks

งานวิจัยนี้เป็นงานที่มีความใกล้เคียงกับโดเมนของโครงงานนี้มากที่สุด โดยมุ่งแก้ปัญหาการจัดสรรช่องสัญญาณและกำลังส่งภายใต้การรบกวนระหว่างเครือข่ายย่อยในระบบ 6G โดยใช้เพียงค่าความแรงสัญญาณ (RSSI) เป็นข้อมูลนำเข้า สถาปัตยกรรมที่นำเสนอชื่อ GA-Net ประกอบด้วยกลไกความสนใจแบบเด็ดขาด (Hard Attention) ที่ใช้เทคนิค Gumbel-Softmax ในการตัดความสัมพันธ์ที่ไม่เกี่ยวข้องออกก่อน แล้วจึงส่งต่อให้กลไกความสนใจแบบอ่อน (Soft Attention) แบบหลายหัว ร่วมกับหน่วยความจำแบบ GRU สำหรับเก็บสถานะย้อนหลัง ผลการทดลองรายงานว่า GA-Net ลู่เข้าเร็วที่สุดและมีความน่าจะเป็นของการขาดการเชื่อมต่อ (Outage Probability) ต่ำที่สุด เมื่อเทียบกับ Actor-Critic, MADDPG, QMIX รวมถึงรุ่นที่ตัดกลไกความสนใจของตนเองออก โดยรายงานผลในรูปแบบกราฟมิได้ระบุเป็นค่าร้อยละเดี่ยว จุดที่งานนี้เป็นแบบอย่างสำคัญคือการประเมินผลด้วยการศึกษาแบบตัดองค์ประกอบภายในสภาพแวดล้อมเดียวกันของตนเอง แทนการนำตัวเลขไปเทียบข้ามงานวิจัย ซึ่งโครงงานนี้ได้นำหลักการดังกล่าวมาใช้ในการออกแบบการทดลอง ข้อจำกัดคือเป็นระบบเครือข่ายย่อย 6G ที่ควบคุมทั้งช่องสัญญาณและกำลังส่ง และมีสถาปัตยกรรมที่ซับซ้อนกว่าบริบทของ Wi-Fi Mesh [15]

2.2.10 Distributed Channel Assignment in Multi-Radio 802.11 Mesh Networks

Ko และคณะ [19] เสนออัลกอริทึมจัดสรรช่องแบบกระจายและ self-stabilizing สำหรับ mesh หลายวิทยุ แต่ละโหนดเลือกช่องที่ลดต้นทุนการรบกวนในพื้นที่ใกล้เคียง ทดสอบบน testbed 14 โหนด และรายงานว่าเพิ่ม capacity ได้ราว

50% เทียบการใช้ช่องเดียวกันทั้งหมด และราว 20% เทียบการสุ่มช่อง โครงงานนี้ใช้แนวคิด local cost ของ Ko เป็นคู่เทียบหลัก และใช้เป็นครูของ behaviour cloning, prior และ fallback ของแบบจำลอง

2.2.11 Graph Convolutional Reinforcement Learning for Resource Allocation in Cognitive Radio Networks

Yuan และคณะ [20] ใช้ deep Q-network ร่วมกับ graph attention เพื่อรวบรวมข้อมูลของโหนดข้างเคียงในการจัดสรรทรัพยากรของ cognitive radio network แบบ overlay–underlay ร่วมกับ network slicing และใช้ KL regulariser ระหว่างน้ำหนักความสนใจของสถานะปัจจุบันกับสถานะถัดไป โครงงานนี้ดัดแปลงเป็นคู่เทียบ Yuan (GAT+DQN) โดยคงโครงสร้าง attention และค่าพารามิเตอร์ของบทความ แต่เปลี่ยน action เป็นช่องและเส้นทาง

2.2.12 Dynamic Allocation of C-V2X Communication Resources Based on GAT and DRL

Li และคณะ [21] เสนอ GAT-A2C ซึ่งใช้ Graph Attention Network เป็นโมดูลรับรู้การรบกวนจากยานพาหนะข้างเคียงร่วมกับ Advantage Actor-Critic ในการจัดสรรทรัพยากร V2V ที่สร้างกราฟใหม่ทุกช่วงเวลา โครงงานนี้ดัดแปลงเป็นคู่เทียบ Li (GAT-A2C) โดยใช้กราฟการรบกวนเป็นกราฟความสนใจและคงขนาดเครือข่ายตามบทความ

งานทั้งสามช่วยกำหนดช่องว่างของโครงงานระยะที่ 2 Ko ทำงานแบบกระจายและอธิบายได้ แต่ตัดสินใจจากต้นทุนเฉพาะหน้า ส่วน Yuan และ Li ใช้ attention แต่ไม่ใช้คุณลักษณะของขอบและไม่ได้เลือกเส้นทาง EGAT-MAPPO จึงรวม attention ที่รับคุณลักษณะของขอบ การตัดสินใจช่องและเส้นทางร่วมกัน และความรู้จาก Ko ไว้ในแบบจำลองเดียว

งานด้าน mesh หลายวิทยุแบบดั้งเดิมศึกษาการจัดสรรช่องร่วมกับการเลือกเส้นทางมานาน เช่น Hyacinth ของ Raniwala และ Chiueh [27], การจัดสรรช่องและเส้นทางร่วมกันเพื่อ throughput ของ Alicherry และคณะ [28], การวิเคราะห์ขีดความสามารถของ Kodialam และ Nandagopal [29] และตัวชี้วัดเส้นทาง WCETT ของ Draves และคณะ [30] งานเหล่านี้ใช้การหาค่าเหมาะสมหรือ heuristic จากภาพรวมของเครือข่าย งานวิจัยที่ทบทวนชี้ว่า MARL ช่วยจัดสรรช่องสัญญาณได้ดีกว่าวิธีดั้งเดิมในหลายสภาวะ แต่ส่วนใหญ่เลือกเฉพาะช่องบนเครือข่าย WLAN แบบ single-hop หรือเครือข่ายเซลลูลาร์ ไม่ได้ตัดสินใจเส้นทางร่วมด้วย งานที่ใช้ graph attention ไม่ได้ใช้คุณลักษณะของลิงก์ เช่น SNR และภาระ ในการให้น้ำหนักเพื่อนบ้าน และการประเมินมักไม่นับต้นทุนของการสลับ ไม่รายงานความแปรปรวนจากการฝึก หรือใช้ตัวชี้วัดเพียงหนึ่งหรือสองตัว โครงงานนี้จึงเสนอ EGAT-MAPPO ที่ตัดสินใจช่องและเส้นทางร่วมกันบน mesh หลาย hop ใช้คุณลักษณะของขอบใน attention นำความรู้จาก Ko มาใช้เป็นจุดเริ่ม และประเมินด้วยคะแนนรวมห้าตัวชี้วัดที่กำหนดไว้ล่วงหน้า สรุปงานที่เกี่ยวข้องแสดงในตารางที่ 1

ตารางที่ 1 ตารางเปรียบเทียบงานวิจัย

ชื่องานวิจัย	วิธีการ (Approach)	ข้อดี (Pros)	ข้อจำกัด (Cons)	ผลลัพธ์เชิงปริมาณที่รายงาน
				ไม่ระบุเป็นค่าร้อยละ

ชื่องานวิจัย	วิธีการ (Approach)	ข้อดี (Pros)	ข้อจำกัด (Cons)	ผลลัพธ์เชิงปริมาณที่รายงาน
[1] Adaptive Channel Assignment for WMNs (2024)	MADDPG แบบ CTDE สำหรับ WMN ตัดสินใจจากข้อมูลท้องถิ่น	ลดสัญญาณรบกวนและปรับตัวตามทราฟฟิกได้ดีกว่าการสุ่ม	ขาด Topology Awareness ทำให้เกิด Herd Behavior เมื่อความหนาแน่นสูง	(รายงานเป็นกราฟเปรียบเทียบ)
[2] Channel Selection for Wi-Fi 7 MLO (2023)	Parallel Transfer RL ร่วมกับ Value Decomposition Networks (VDN)	รองรับ Multi-Link Operation; เร่งการลู่เข้าได้เร็วขึ้น	เจาะจงกับมาตรฐาน Wi-Fi 7 MLO; ไม่ได้เทียบกับวิธี MARL อื่นชัดเจน	ผลตอบแทนสูงกว่า VDN ปกติ ร้อยละ 3–11 ลู่เข้าเร็วขึ้นประมาณ 40 Episodes
[3] Learning-Based Algorithms for Channel Allocations in WMN (2022)	Spatial Adaptive Play (SAP) และ MARL สำหรับ Backhaul Links	เพิ่มจำนวนลิงก์ที่สื่อสารสำเร็จ ดีกว่าวิธีเชิงทฤษฎีเกมดั้งเดิม	ไม่ได้ใช้โครงสร้างกราฟช่วยการตัดสินใจของตัวแทน	ไม่ระบุเป็นค่าร้อยละ (รายงานเป็นจำนวนลิงก์ที่สำเร็จ)

ตารางที่ 1 ตารางเปรียบเทียบงานวิจัย (ต่อ)

ชื่องานวิจัย	วิธีการ (Approach)	ข้อดี (Pros)	ข้อจำกัด (Cons)	ผลลัพธ์เชิงปริมาณที่รายงาน
[4] QLBT: MARL for Distributed Channel Access (2022)	QMIX-advanced Listen-Before-Talk บนพื้นฐาน CTDE	เหนือกว่า CSMA/CA ทั้งทราฟฟิกสูงและต่ำ; ทำงานร่วมกับอุปกรณ์เดิมได้	เป็นการเข้าถึงช่องระดับ MAC Layer มิใช่การจัดสรรช่องระดับ AP	ไม่ระบุเป็นค่าร้อยละ (รายงานเป็นกราฟ Throughput)
[5] MACRL for Dynamic Topology (2024)	Multi-Agent Actor-Critic แบบ CTDE ทดสอบบน QualNet	ลดความหน่วงและเพิ่มประสิทธิภาพการใช้ช่องสัญญาณ	เน้นการขยายเครือข่าย ยังไม่กล่าวถึง Overhead และ Scalability	ไม่ระบุเป็นค่าร้อยละ (รายงานเป็นกราฟ Latency)
[6] Heterogeneous MARL for WLAN Access (2025)	QPMIX รองรับตัวแทนที่ใช้วิธีเรียนรู้ต่างกัน (Value/Policy-based)	เพิ่ม Throughput ลด Delay/Jitter และลดการชนกันในสภาวะโหลดสูง	เป็นการเข้าถึงช่องระดับ MAC มิใช่การจัดสรรช่องใน Mesh	ไม่ระบุเป็นค่าร้อยละ (ไม่ได้แสดงตัวเลขเฉพาะเจาะจง)
[7] Real-Time Channel Management in WLANs (2021)	net2seq (Actor-Critic) เทียบกับ Heuristic ทดสอบบนเครือข่ายจริง 34 AP	เหนือกว่า Heuristic ในเครือข่ายขนาดใหญ่; ทดสอบบนเครือข่ายจริง	เป็นการควบคุมจากศูนย์กลาง; ต้องฝึกสอนล่วงหน้า	ไม่ระบุเป็นค่าร้อยละ (รายงานเป็นกราฟ Throughput)
[8] GAT-based MARL for Slicing Resource Management (2021)	GAT วางหน้าส่วนรับข้อมูลของ DQN และ A2C ในเครือข่ายเซลลูลาร์	พิสูจน์ว่า GAT ยกระดับ DRL ได้ทั้งแบบ Value-based และ Actor-critic	เป็นการแบ่งส่วนเครือข่าย 5G มิใช่ Wi-Fi Mesh; ไม่จัดการความไม่เสถียรของ Attention	System Utility เพิ่มขึ้นร้อยละ 4 (GAT-DQN) ร้อยละ 5 (GAT-A2C) และร้อยละ 7 ที่ความละเอียดสูง

ตารางที่ 1 ตารางเปรียบเทียบงานวิจัย (ต่อ)

ชื่องานวิจัย	วิธีการ (Approach)	ข้อดี (Pros)	ข้อจำกัด (Cons)	ผลลัพธ์เชิงปริมาณที่รายงาน
[9] GA-Net for 6G in-X Subnetworks (2022)	Hard Attention (Gumbel-Softmax) + Multi-head GAT + GRU ใช้ RSSI เป็นข้อมูลนำเข้า	ทนทานต่อการสังเกตไม่สมบูรณ์; มี Ablation ในสภาพแวดล้อมเดียวกัน	เป็นเครือข่ายย่อย 6G ควบคุมทั้งช่องและกำลังส่ง; สถาปัตยกรรมซับซ้อน	ไม่ระบุเป็นค่าร้อยละ (รายงานเป็นกราฟ Convergence และ Outage Probability)
[10] Distributed Channel Assignment in Multi-Radio 802.11 Mesh (2007)	Local cost แบบกระจาย self-stabilizing บน mesh หลายวิทยุ	ไม่ต้องฝึก ทำงานกระจาย อธิบายได้	ตัดสินใจจากต้นทุนเฉพาะหน้า ไม่ได้เลือกเส้นทาง	capacity เพิ่มราว 50% เทียบช่องเดียว และ 20% เทียบสุ่ม (testbed 14 โหนด)
[11] Graph Convolutional RL for Cognitive Radio (2022)	DQN + graph attention + KL ระหว่าง attention ต่อเนื่อง	ใช้ข้อมูลเพื่อนบ้าน off-policy	ไม่ใช้คุณลักษณะของขอบ action space ใหญ่	รายงานในบริบท cognitive radio + slicing
[12] GAT-A2C for C-V2X Resource Allocation (2025)	GAT รับรู้การรบกวน + Advantage Actor-Critic	actor-critic ใช้กราฟการรบกวน	on-policy ความแปรปรวนสูง ไม่ใช้คุณลักษณะของขอบ	รายงานในบริบท V2V

ชื่องานวิจัย	วิธีการ (Approach)	ข้อดี (Pros)	ข้อจำกัด (Cons)	ผลลัพธ์เชิงปริมาณที่รายงาน
[13] งานนี้: EGAT-MAPPO (2569)	GATv2 **รับคุณลักษณะของขอบ + MAPPO + Ko prior เลือกช่องและเส้นทางร่วมกัน พร้อม hysteresis ขณะใช้งาน**	ตัดสินใจแบบกระจาย ใช้ข้อมูลลิงก์ ลดการสลับ ประเมินด้วยโปรโตคอลที่กำหนดไว้ล่วงหน้า	ส่วนต่างเหนือ Yuan ที่ใส่ hysteresis ไม่ถึง 10% ยืนยันบน ns-3 เพียง 3 สถานการณ์	คะแนนรวม (topology ยืนยัน) ดีกว่า Ko +24.6%, Li +17.9%, Yuan +24.8%, Yuan+H +6.7%; สลับน้อยกว่า Ko 93%

บทที่ 3

วิธีการดำเนินงาน

โครงงานดำเนินงานเป็นสองระยะ ระยะที่ 1 พัฒนา GAT+RAES และประเมินด้วย native ns-3 แบบ single-hop ระยะที่ 2 ซึ่งเป็นผลหลักของรายงานนี้ พัฒนา EGAT-MAPPO สำหรับ mesh หลาย hop บนสภาพแวดล้อม Python ที่สร้างขึ้นใหม่ บทนี้อธิบายเครื่องมือและขั้นตอนของระยะที่ 2 และวิธีประเมินในหัวข้อ 3.4

3.1 เครื่องมือที่ใช้ในการดำเนินงาน

3.1.1 ภาษา Python ใช้พัฒนาสภาพแวดล้อมจำลอง ตัวแทนการเรียนรู้ คู่เทียบ และสคริปต์ประเมินผล ทุกการทดลองบันทึก commit ของโค้ดไว้ในรายงานผล

3.1.2 ไลบรารี PyTorch ใช้สร้างและฝึก EGAT-MAPPO และคู่เทียบที่เป็นโครงข่ายประสาท ฝึกบน GPU ครั้งละไม่เกิน 3 งาน และประเมินผลบน CPU

3.1.3 ไลบรารี NumPy และ SciPy ใช้คำนวณแบบจำลองช่องสัญญาณ การจัดสรร throughput และการทดสอบทางสถิติ

3.1.4 ไลบรารี Matplotlib ใช้สร้างภาพผลการทดลอง และ pytest ใช้ทดสอบความถูกต้องของโค้ด (167 การทดสอบ)

3.1.5 โปรแกรมจำลอง ns-3 รุ่น 3.47 ใช้ปรับเทียบสภาพแวดล้อมจำลองและยืนยันผลในระดับแพ็กเก็ต โดยเชื่อมกับ Python ผ่านโปรแกรมตัวกลาง (bridge) ที่รับการกระทำจากนโยบายทุกขั้นเวลา

3.2 ขั้นตอนการดำเนินงาน

การดำเนินงานระยะที่ 2 แบ่งเป็น 6 ขั้นตอน ดังนี้

3.2.1 การวิเคราะห์ปัญหาและความต้องการ

ทบทวนผลระยะที่ 1 ซึ่งจำกัดอยู่ที่ single-hop และพบว่าใน mesh หลาย hop การเลือกช่องกับการเลือกเส้นทางส่งผลต่อกัน การเปลี่ยนช่องของโหนดแม่กระทบลูกทุกตัว และการสลับบ่อยทำให้เกิดช่วงหยุดส่งและการสูญเสียคิว จึงกำหนดให้ตัดสินใจทั้งสองอย่างร่วมกันและนับต้นทุนของการสลับไว้ในแบบจำลอง

3.2.2 การศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้อง

ศึกษา GATv2, PPO, GAE และ MAPPO และงานคู่เทียบของ Ko, Yuan และ Li เพื่อระบุจุดเด่นที่นำมาใช้และจุดอ่อนที่ต้องแก้ ดังสรุปในบทที่ 2

3.2.3 การออกแบบสภาพแวดล้อมจำลอง

สร้างสภาพแวดล้อม mesh หลายตัวแทนที่มี topology สุ่ม แบบจำลอง PHY ของ 802.11ax การแบ่ง airtime ระหว่างลิงก์ที่รบกวนกัน ทราฟฟิกแบบ on/off และต้นทุนการสลับช่องและเส้นทาง รายละเอียดอยู่ในหัวข้อ 4.1 และพารามิเตอร์อยู่ในตารางที่ 3

3.2.4 การพัฒนาคู่เทียบ

พัฒนา M0 และ Ko เป็น heuristic และพัฒนา Q-neutral, Yuan และ Li เป็นตัวแทนที่เรียนรู้ ทุกวิธีใช้ observation, action, รูปแบบ reward และงบการฝึกเดียวกัน การดัดแปลงจากบทความต้นฉบับทุกจุดบันทึกพร้อมเหตุผล และทดสอบคู่เทียบให้ทำงานถูกต้องก่อนเริ่มพัฒนาแบบจำลองของเรา

3.2.5 การพัฒนาและฝึก EGAT-MAPPO

พัฒนาแบบจำลองตามหัวข้อ 4.2 ฝึก 100,000 ขั้นเวลาต่อการฝึกหนึ่งครั้ง (10,000 ขั้นแรกเป็น behaviour cloning) ด้วย 5 ค่าเมล็ดสุ่ม และเลือก checkpoint ด้วยคะแนนรวมบน topology สำหรับ validation ที่แยกจากชุดทดสอบ

3.2.6 การทดสอบและประเมินผล

ประเมินทุกวิธีบนชุดทดสอบเดียวกันตามโปรโตคอลในหัวข้อ 3.4 แล้ววิเคราะห์ที่มาของผลด้วยการแยกคะแนนรายตัวชี้วัด การทดลองความเป็นธรรมของกลไกลดการสลับ การยืนยันบน topology ใหม่ และการตัดองค์ประกอบ

3.3 แผนและระยะเวลาการดำเนินงาน

รายละเอียดแสดงในตารางที่ 2

ตารางที่ 2 แผนการดำเนินงานโครงงาน GAT–MARL และการตรวจสอบด้วย ns-3

กิจกรรมโครงงาน	**สัปดาห์ที่ / เดือน**																																					
	ปี 2568																												**ปี 2569**											
	มิ.ย.				**ก.ค**				**ส.ค**				**ก.ย.**				**ต.ค.**				**พ.ย.**				**ธ.ค.**				**ม.ค.**				**ก.พ.**				**มี.ค.**			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1. วิเคราะห์ปัญหา Wi-Fi Mesh และตัวชี้วัด	■																																					
2. ศึกษา GAT, MARL/DDQN และงานที่เกี่ยวข้อง		■																																				
3. ศึกษา Python, PyTorch, ns-3 และ LibTorch			■																																			
4. กำหนดขอบเขต สมมติฐาน และการทดลอง				■																																		
5. จัดทำและนำเสนอเค้าโครงโครงงาน					■	■	■	■	■	■	■	■																										
6. ออกแบบ Environment, Graph State, Reward และ Baseline													■	■	■	■	■	■	■	■																		
7. พัฒนา GAT-DDQN และ risk-aware selector																					■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	
8. รายงานความก้าวหน้าครั้งที่ 1																																						■

ตารางที่ 2 แผนการดำเนินงานโครงงาน GAT–MARL และการตรวจสอบด้วย ns-3 (ต่อ)

กิจกรรมโครงงาน	สัปดาห์ที่ / เดือน																																			
	ปี 2569																																			
	เม.ย.				พ.ค.				มิ.ย.				ก.ค.				ส.ค.				ก.ย.				ต.ค.				พ.ย.				ธ.ค.				เม.ย.			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
9. พัฒนา ns-3 validation และ embedded LibTorch	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■	■																					
10. รายงานความก้าวหน้าครั้งที่ 2																				■																				
11. ทดสอบ 9 วิธีและ stress scenarios																					■	■	■	■																
12. วิเคราะห์ผล paired tests และ confidence intervals																									■															
13. ปรับปรุง Research Paper และ Progress Report																										■	■													
14. สรุปผล จัดทำเอกสาร และนำเสนอ																												■												

3.4 วิธีประเมินผล

ชุดทดสอบประกอบด้วยสถานการณ์กลุ่ม A (S1–S6) ซึ่งเป็นสภาวะทั่วไป และกลุ่ม B (B1–B5) ซึ่งเจาะจุดอ่อนที่ทราบของคู่เทียบ ทุกสถานการณ์ใช้ 20 topology (ค่าเมล็ดสุ่ม 0–19) และยืนยันซ้ำบน topology ใหม่สองชุด (20–39 และ 40–59) ส่วนกลุ่ม C (C1–C5) เป็นสภาวะที่กำหนดไว้ล่วงหน้าว่าแบบจำลองที่เรียนรู้อาจเสียเปรียบ รายละเอียดอยู่ในตารางที่ 5 ทุกวิธีที่เรียนรู้ฝึก 5 ค่าเมล็ดสุ่ม แต่ละโมเดลถูกทดสอบบนทุก topology ส่วน M0 และ Ko เป็น heuristic ที่ให้ผลแน่นอนเมื่อรู้ topology

ตัวชี้วัดมีห้าตัว ได้แก่ throughput รวม, Jain fairness index, throughput เปอร์เซ็นไทล์ที่ 5 ของ flow (p5), อัตราสูญเสีย และความเสถียร (จำนวนการสลับช่องรวมกับการเปลี่ยนโหนดแม่ต่อ episode) คะแนนรวมของวิธี M เทียบวิธีอ้างอิง R ในแต่ละสถานการณ์คือผลรวมถ่วงน้ำหนักของการปรับปรุงเชิงสัมพัทธ์ที่ตัดไว้ในช่วง [−1, 1] ด้วยน้ำหนัก 0.25, 0.20, 0.20, 0.20 และ 0.15 ตามลำดับ แล้วเฉลี่ยข้ามสถานการณ์ คะแนนรวม +0.10 หมายถึงดีกว่า 10% รายงานนี้จึงแสดงคะแนนรวมเป็นร้อยละ (เช่น 0.219 แสดงเป็น 21.9%)

การปรับปรุงเชิงสัมพัทธ์ d ของแต่ละตัวชี้วัด คำนวณจากค่าเฉลี่ยของตัวชี้วัดในสถานการณ์นั้น โดย x_M คือค่าของวิธีที่ประเมิน และ x_R คือค่าของวิธีอ้างอิง

(1) ตัวชี้วัดที่ยิ่งมากยิ่งดี (throughput รวม, Jain fairness, p5): d = (x_M − x_R) / x_R

(2) อัตราสูญเสีย (ยิ่งน้อยยิ่งดี): d = (x_R − x_M) / max(x_R, 0.01)

(3) จำนวนการสลับ (ยิ่งน้อยยิ่งดี): d = (x_R − x_M) / (x_R + 1) โดยบวก 1 เพราะบางวิธีไม่สลับเลย

แต่ละ d ถูกตัดให้อยู่ในช่วง [−1, 1] แล้วคะแนนรวมของสถานการณ์นั้นคือ 0.25·d(throughput) + 0.20·d(Jain) + 0.20·d(p5) + 0.20·d(อัตราสูญเสีย) + 0.15·d(การสลับ) จากนั้นเฉลี่ยข้าม 11 สถานการณ์ของกลุ่ม A และ B

ตัวอย่าง EGAT+H เทียบ Ko ในสถานการณ์ S2: throughput 66.87 เทียบ 55.42 Mb/s ได้ d = 20.7% คูณ 0.25 ได้ 5.2%; Jain 0.802 เทียบ 0.767 ได้ 4.6% คูณ 0.20 ได้ 0.9%; p5 1.757 เทียบ 1.447 Mb/s ได้ 21.4% คูณ 0.20 ได้ 4.3%; อัตราสูญเสีย 0.240 เทียบ 0.374 ได้ d = (0.374 − 0.240) / 0.374 = 35.8% คูณ 0.20 ได้ 7.2%; การสลับ 44.3 เทียบ 771.4 ครั้ง ได้ d = (771.4 − 44.3) / 772.4 = 94.1% คูณ 0.15 ได้ 14.1% รวมเป็นคะแนนรวมของ S2 เท่ากับ +31.7% เมื่อเฉลี่ยทั้ง 11 สถานการณ์จะได้ +26.0% ซึ่งแยกเป็นส่วนของแต่ละตัวชี้วัดได้ตามตารางที่ 7

เกณฑ์ความสำเร็จที่กำหนดไว้ล่วงหน้ามี 4 ข้อ (1) คะแนนรวมเฉลี่ยบน A+B เทียบทุกคู่เทียบไม่ต่ำกว่า +10% (2) ดีกว่าอย่างมีนัยสำคัญ (Holm, $\alpha = 0.05$) ในอย่างน้อย 60% ของสถานการณ์ (3) ไม่มีสถานการณ์ใดแย่กว่า Ko เกิน 5% และ (4) เกณฑ์ข้อ 1 ยังผ่านเมื่อปรับน้ำหนักตัวใดตัวหนึ่งลดครึ่งหรือเพิ่มครึ่ง

การทดสอบรายสถานการณ์ใช้ Wilcoxon signed-rank และ paired bootstrap ทั้งสองปรับด้วย Holm ข้ามสถานการณ์ การทดสอบนี้ถือว่าแต่ละ run เป็นอิสระและไม่นับความแปรปรวนของการฝึก จึงอาจประเมินนัยสำคัญสูงกว่าความจริง สำหรับค่าเฉลี่ยข้ามสถานการณ์ จึงคำนวณคะแนนรวมของทุกคู่ (ค่าเมล็ดสุ่มการฝึกของเรา, ของคู่เทียบ) แล้วรายงานค่าเฉลี่ยพร้อมช่วงความเชื่อมั่น 95% แบบ t ที่รวมความแปรปรวนระหว่างค่าเมล็ดสุ่มของทั้งสองวิธี (Welch–Satterthwaite) ช่วงนี้ยังไม่นับความแปรปรวนจากการสุ่ม topology ทดสอบ

setting หลัก (a) คือเมื่อโหนดสลับช่องหรือเส้นทาง คิวที่รอบนลิงก์ที่ถูกตัดจะสูญหาย ส่วน setting (b) ให้ทุกวิธีเก็บคิวไว้ระหว่างสลับได้ เพื่อแยกผลของการวางแผนจากผลของการเก็บคิว

การเปิดเผยการตัดสินใจหลังเห็นผล: เอกสารข้อกำหนดของการทดลองถูกแก้ไข 7 ครั้งระหว่างการทำงาน ทุกครั้งบันทึกพร้อมวันที่ ได้แก่ การเพิ่มต้นทุนการสลับในสภาพแวดล้อมจำลองหลังการทดลองนำร่องพบว่าแทบไม่มีช่องให้ดีกว่า Ko, การเพิ่ม switch hysteresis และกติกาเลือก margin และการเปลี่ยนวิธีคำนวณช่วงความเชื่อมั่น ซึ่งสามข้อหลังเกิดหลังการประเมินชุดทดสอบครั้งแรก นอกจากนี้ได้ประเมินแบบจำลองหลายรุ่น (EGAT, v1, v2 ทั้งที่มีและไม่มี hysteresis) บน topology ทดสอบ 0–19 แล้วรายงานรุ่นที่ดีที่สุด margin เลือกจาก topology validation (ค่าเมล็ดสุ่ม 1000–1003) เท่านั้น แล้วรันชุดทดสอบครั้งเดียว และเพื่อยืนยัน ได้ประเมินซ้ำบน topology ใหม่ (ค่าเมล็ดสุ่ม 20–39) ที่ไม่เคยใช้ตัดสินใจใด ในขณะนั้น

หลังจากนั้นเมื่อนำนโยบายไปรันบน ns-3 พบว่าแบบจำลอง airtime รุ่นแรกประเมิน throughput ในช่องที่แออัดเกินจริง จึงเปลี่ยนแบบจำลองและปรับเทียบกับ ns-3 (หัวข้อ 4.6) แล้วฝึกและประเมินทุกวิธีที่เรียนรู้ใหม่ทั้งหมดด้วยสูตรการฝึก กติกาเลือก checkpoint และกติกาเลือก margin เดิม ผลทั้งหมดในบทที่ 4 มาจากรอบนี้ ในรอบนี้ margin ของแบบจำลองที่มี GRU ถูกเลือกครั้งแรกโดยเทียบกับ Ko อย่างเดียว ได้ m = 1 ซึ่งไม่ตรงกับกติกา worst-case ที่กำหนดไว้ เมื่อพบจึงเลือกใหม่ตามกติกาได้ m = 2 และไม่ได้ใช้ผลของ m = 1

การเปลี่ยนแบบจำลองหลักเป็นแบบที่ไม่มี GRU: เดิมแบบจำลองหลักมีหน่วยความจำ GRU รายโหนด (เรียกว่า EGAT+GRU+H) ซึ่งเสมอกับ Yuan+H ในการตัดองค์ประกอบบน topology ทดสอบ 0–19 (หัวข้อ 4.4.6) แบบที่ตัด GRU ออกดีกว่า Yuan+H อย่างมีนัยสำคัญ แต่ผลนี้ได้หลังเห็นชุดทดสอบ จึงเขียนโปรโตคอลยืนยันไว้ก่อนรัน (docs/paper/protocol_nogru.md วันที่ 7 พฤศจิกายน 2569) ซึ่งกำหนดแบบจำลอง ค่าเมล็ดสุ่มการฝึก 0–4 (ค่า 0–2 ใช้ checkpoint จากการตัดองค์ประกอบ) กติกาเลือก margin เดิม topology ชุดใหม่ 40–59 ที่ไม่เคยใช้ในการทดลองใด และเกณฑ์ตัดสิน 3 ข้อ คือ (P1) ดีกว่า Yuan+H เฉลี่ยอย่างน้อย +5% และขอบล่างของช่วงความเชื่อมั่นเกิน 0 (P2) ขอบล่างเกิน 0 เทียบ Ko, Li, Yuan, M0, Q-neutral และ Li+H และ (P3) ผ่านเกณฑ์ความสำเร็จ 4 ข้อ ถ้าผ่าน P1 และ P2 จะใช้แบบที่ไม่มี GRU เป็นแบบจำลองหลัก มิฉะนั้นคงแบบเดิม และห้ามเปลี่ยนแบบจำลอง margin หรือสถานการณ์หลังเห็นผล ผลผ่านครบทั้งสามข้อ (หัวข้อ 4.4.4) ผลในบทที่ 4 จึงเป็นของแบบที่ไม่มี GRU (เรียกว่า EGAT+H หรือ EGAT-MAPPO) ซึ่ง margin ที่เลือกได้คือ m = 2 เท่าเดิม topology 40–59 เป็นชุดที่ใช้อ้างอิงมากที่สุด เพราะ topology 0–19 ถูกใช้ในการเลือกโครงสร้างนี้ และ topology 20–39 เคยใช้ประเมินแบบที่มี GRU แล้ว

3.4.1 ที่มาของคู่เทียบและขอบเขตการดัดแปลง

M0 ใช้ช่องคงที่และเส้นทาง hop น้อยที่สุด ไม่สลับเลย Ko ดัดแปลงจาก local cost ของ Ko และคณะ [19] ทุก 10 ขั้นเวลา หรือทันทีเมื่อลิงก์ไปโหนดแม่ขาด จะหาเส้นทางด้วย Bellman-Ford ที่ต้นทุนลิงก์ (1 + สัดส่วนภาระ)/อัตราส่ง เปลี่ยนโหนดแม่เมื่อต้นทุนใหม่ต่ำกว่า 0.9 เท่าของเดิม แล้วเลือกช่อง downlink ที่ถูกใช้น้อยที่สุดโดยเพื่อนบ้านที่รบกวน Q-neutral คือ Q-learning แบบตารางที่ใช้ reward ร่วม เนื่องจากเอกสารโครงงานระบุชื่อโดยไม่นิยาม จึงเป็นการตีความของผู้จัดทำ

Yuan [20] และ Li [21] คงโครงสร้าง attention และค่าพารามิเตอร์ตามบทความ แต่ทั้งสองบทความเลือกช่องและกำลังส่งโดยไม่มีการเลือกเส้นทาง จึงเปลี่ยน action เป็นช่องและเส้นทางแบบเดียวกับวิธีของเรา จุดที่บทความไม่ได้ระบุหรือใช้ไม่ได้ เช่น ขนาด Q head ของ Yuan และอัตราการเรียนรู้ของ Li ที่ทำให้ softmax อิ่มตัวเมื่อปรับทุกขั้นเวลา ได้ปรับและบันทึกเหตุผลไว้ทุกจุด ทุกวิธีที่เรียนรู้ใช้ตัวถอดรหัสช่องแบบลำดับเดียวกับวิธีของเรา จึงไม่ได้เปรียบกัน และไม่มีคู่เทียบใดใช้คุณลักษณะของขอบ ซึ่งเป็นส่วนหนึ่งของข้อเสนอของโครงงาน

ใน ablation ความเป็นธรรม ได้ใส่ hysteresis ให้ Li และ Yuan ด้วยกติกาเลือก margin เดียวกัน (Li+H, Yuan+H) โดยใช้คู่เทียบเดิม ไม่ใช้ EGAT-MAPPO เป็นตัวอ้างอิงในการเลือก grid ของ margin ต่างกันตามวิธี คือ {0, 0.5, 1, 2, 3, 4} สำหรับ EGAT-MAPPO และ {0, 0.25, 0.5, 1, 2, 4, 8, 16} สำหรับ Li และ Yuan ได้ margin 1 ทั้ง Li และ Yuan ส่วน Ko คงไว้ตามกฎ local cost ของงานต้นฉบับ ไม่ได้เพิ่มกลไกที่งานนั้นไม่มี

บทที่ 4

การวิเคราะห์ระบบและผลการทดลอง

4.1 การกำหนดรูปแบบของปัญหาและแบบจำลองระบบ

4.1.1 แบบจำลองเครือข่ายและช่องสัญญาณ

เครือข่ายมี n โหนด (ค่าเริ่มต้น 20) วางแบบสุ่มในพื้นที่สี่เหลี่ยมด้าน $30\sqrt{n}$ เมตร และสุ่มใหม่จนกราฟลิงก์เชื่อมถึงกัน มี 2 gateway สุ่มตำแหน่ง ลิงก์มีอยู่เมื่อกำลังรับไม่ต่ำกว่า −76 dBm และโหนดสองตัวรบกวนกันเมื่อกำลังรับไม่ต่ำกว่า −82 dBm กำลังรับคำนวณจาก log-distance path loss ตามค่าเริ่มต้นของ ns-3 [18] (กำลังส่ง 20 dBm, reference loss 46.68 dB ที่ 1 เมตร, exponent 3) noise −94 dBm แล้วแปลง SNR เป็นอัตราส่งตามตาราง MCS ของ 802.11ax (20 MHz, 1 spatial stream) ตั้งแต่ 8.6 ถึง 143.4 Mb/s

แต่ละโหนดมี 2 วิทยุ วิทยุ 1 เป็น downlink เลือกได้ 6 ช่อง (ช่อง 6 และ 11 ของ 2.4 GHz และช่อง 36–48 ของ 5 GHz) วิทยุ 0 เป็น uplink ใช้ช่องเดียวกับ downlink ของโหนดแม่ ทำให้ทุกลิงก์ในต้นไม้เส้นทางมีช่องที่ใช้ร่วมกัน

การแบ่ง airtime ใช้แบบจำลองโดเมนการรบกวน (interference domain) ลิงก์ที่ใช้ช่องเดียวกันและปลายใดปลายหนึ่งอยู่ในระยะรบกวนกันถือว่าอยู่ในโดเมนเดียวกัน airtime ที่ลิงก์ l ต้องการคือภาระของ l หารด้วยอัตราส่ง และ airtime รวมของโดเมนรอบลิงก์ใดต้องไม่เกิน $\eta = 0.65$ ของเวลาทั้งหมด โดเมนที่ต้องการเกินจะลดทุก flow ที่ผ่านลงตามสัดส่วน ลิงก์ที่ว่างไม่ใช้ airtime จึงไม่ทำให้เพื่อนบ้านเสียโอกาส ค่า η แทน overhead ของ MAC และการชนกัน และได้จากการปรับเทียบกับ ns-3 (หัวข้อ 4.6) แบบจำลองนี้แทนการแบ่ง airtime เท่ากันตามจำนวนลิงก์ที่ใช้งาน (1/k) ที่ใช้ในรุ่นแรก ซึ่งการปรับเทียบพบว่าไม่ได้ปล่อย airtime ที่ไม่ได้ใช้ให้ลิงก์อื่น และประเมิน throughput เกินจริงในช่องที่แออัดถึง 22–28%

4.1.2 ทราฟฟิกและต้นทุนการสลับ

ทุกโหนดที่ไม่ใช่ gateway เป็นต้นทางของทราฟฟิก uplink ไปยัง gateway ตามสายโหนดแม่ ความต้องการของแต่ละโหนดเป็นสาย Markov แบบ on/off ที่คงสถานะด้วยความน่าจะเป็น 0.9 ต่อขั้น ขณะ on สุ่มอัตราจากการแจกแจงเอ็กซ์โพเนนเชียลตามค่าเฉลี่ยของสถานการณ์ ทราฟฟิกที่ส่งไม่ทันเข้าคิว ส่วนที่เกินขนาดคิวสูญหาย หนึ่งขั้นเวลาเท่ากับ 100 ms และหนึ่ง episode มี 200 ขั้น

โหนดที่เปลี่ยนช่อง downlink ใช้ลิงก์บนช่องนั้นไม่ได้ 1 ขั้นเวลา และโหนดที่เปลี่ยนโหนดแม่ใช้ uplink ไม่ได้ 1 ขั้นเวลา ใน setting (a) flow ที่เส้นทางผ่านลิงก์ที่ถูกตัดจะสูญเสียคิวที่รออยู่ด้วย ต้นทุนนี้ทำให้การสลับบ่อยมีผลเสียจริง ไม่ใช่เพียงค่าปรับใน reward

4.1.3 เซตของตัวแทน ปริภูมิสถานะ และการกระทำ

ทุกโหนด รวมทั้ง gateway เป็นตัวแทนและตัดสินใจทุกขั้นเวลา ตัวแทน i สังเกตภาระที่เสนอ ความต้องการที่ยังไม่ได้รับ คิว สถานะ gateway จำนวน hop ถึง gateway การทำงาน ช่องปัจจุบัน และโหนดแม่ปัจจุบัน และสำหรับโหนดแม่ที่เป็นไปได้ 4 ตัว (เรียงตาม hop แล้วตาม SNR) สังเกตความใช้ได้ SNR อัตราส่ง และสัดส่วนภาระ ขอบของกราฟเชื่อมโหนดที่

มีลิงก์หรือรบกวนกัน และมีคุณลักษณะ 7 ตัว ได้แก่ การเป็นลิงก์ การรบกวน SNR อัตราส่ง สัดส่วนภาระ การใช้ช่องร่วมกัน และอัตราส่วนที่ส่งสำเร็จของขั้นก่อน

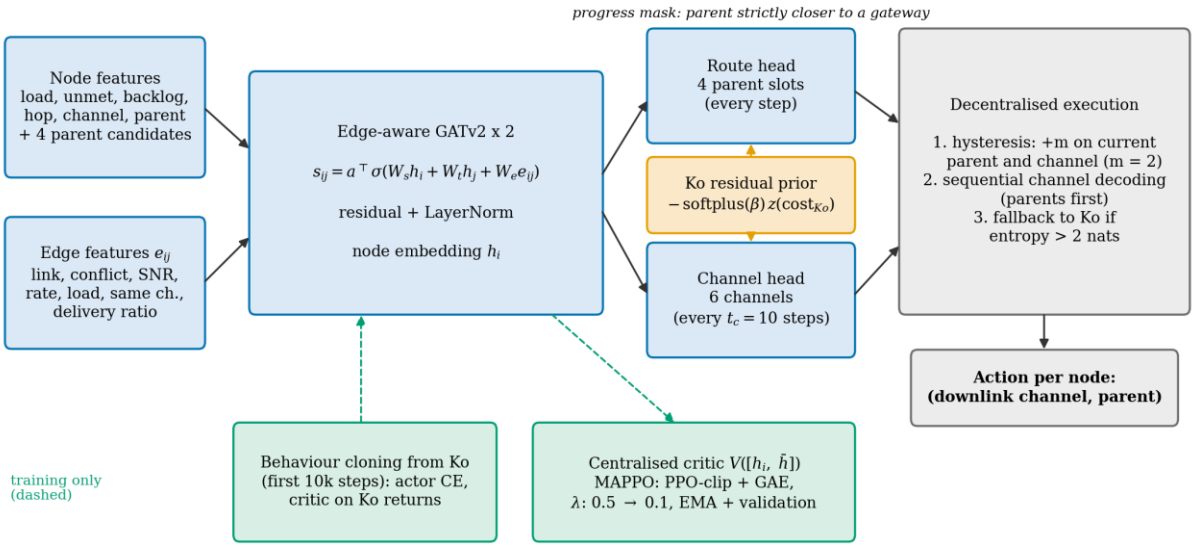
การกระทำคือคู่ (ช่อง downlink, ช่องโหนดแม่) จำนวน 6 × 4 = 24 แบบ

4.1.4 ฟังก์ชันผลตอบแทน

ผลตอบแทนของระบบคือ R = Σ log($\bar{x}$_f + 0.01) − 0.1·N_sw − 0.05·N_rc − 0.1·N_drop เมื่อ $\bar{x}$_f คือ throughput ของ flow f เฉลี่ยในหน้าต่าง 1 วินาที และ N_sw, N_rc, N_drop คือจำนวนการสลับช่อง การเปลี่ยนโหนดแม่ และ flow ที่หาเส้นทางไม่ได้ ผลรวม log ให้ความเป็นธรรมแบบ proportional fairness ผลตอบแทนรายตัวแทนคือ r_i = λ·u_i + (1 − λ)·R/n_alive − 0.1·s_i − 0.05·c_i เมื่อ u_i คือ utility ของ flow ที่ผ่านโหนด i และ s_i, c_i คือการสลับของโหนดเอง คู่เทียบใช้ λ = 0.5 ตลอด ส่วน EGAT-MAPPO ลด λ เชิงเส้นจาก 0.5 เป็น 0.1 ระหว่างฝึก เพื่อให้สัญญาณการฝึกเข้าใกล้เป้าหมายรวมของระบบ

4.2 การออกแบบสถาปัตยกรรมของ EGAT-MAPPO

ภาพที่ 1 แสดงภาพรวมของ EGAT-MAPPO ข้อมูลของโหนดและของขอบผ่านตัวเข้ารหัสกราฟไปยังหัวเลือกเส้นทางและหัวเลือกช่อง ซึ่งรวม residual prior จาก Ko แล้วจึงผ่านขั้นการทำงานแบบกระจายศูนย์เพื่อได้การกระทำของแต่ละโหนด ส่วนที่เป็นเส้นประใช้เฉพาะตอนฝึก



ภาพที่ 1 สถาปัตยกรรมของ EGAT-MAPPO (σ คือ LeakyReLU, กล่องสีส้มคือส่วนที่มาจาก Ko, กล่องสีเขียวและเส้นประใช้เฉพาะตอนฝึก)

4.2.1 ตัวเข้ารหัสกราฟที่รับคุณลักษณะของขอบ

คุณลักษณะโหนดผ่านชั้น linear แล้วเข้าสู่ GATv2 สองชั้น 4 หัว ขนาดซ่อน 64 คะแนนความสนใจของโหนด i ต่อเพื่อนบ้าน j คือ s_ij = $a^\top$ LeakyReLU(W_s h_i + W_t h_j + W_e e_ij) โดย e_ij คือคุณลักษณะของขอบ แล้ว

normalise ด้วย softmax เหนือเพื่อนบ้านและตัวเอง แต่ละชั้นมี residual connection และ LayerNorm ผลลัพธ์คือ embedding ของโหนดที่ส่งต่อไปยังหัวตัดสินใจโดยตรง แบบจำลองไม่มีหน่วยความจำข้ามขั้นเวลา และตัดสินใจจาก observation ของขั้นปัจจุบันเท่านั้น รุ่นแรกมี GRU รายโหนดต่อจาก GATv2 แต่ตัดออกตามผลการตัดองค์ประกอบ (หัวข้อ 4.4.6) และการยืนยันในหัวข้อ 3.4 พารามิเตอร์ใช้ร่วมกันทุกโหนด

4.2.2 หัวตัดสินใจสองช่วงเวลาและ progress mask

หัวเลือกช่องและหัวเลือกเส้นทางแปลงสถานะของโหนดเป็น logits ของ 6 ช่องและ 4 โหนดแม่ หัวเลือกเส้นทางตัดสินใจทุกขั้น ส่วนหัวเลือกช่องตัดสินใจทุก 10 ขั้น เพราะการเปลี่ยนช่องมีต้นทุนสูงกว่า progress mask อนุญาตเฉพาะโหนดแม่ที่อยู่ใกล้ gateway กว่าอย่างเคร่งครัด จึงไม่เกิดวงวนของเส้นทาง

4.2.3 Residual prior จาก Ko

ทั้งสองหัวลบต้นทุนของ Ko ที่ normalise แล้ว คูณด้วยสเกลที่เรียนได้ คือ logits ← logits − softplus(β)·z(cost_Ko) โดยเริ่มที่ softplus(β) = 1 แบบจำลองจึงเริ่มใกล้ Ko และเรียนเฉพาะส่วนที่ปรับแก้

4.2.4 การฝึก

ช่วงแรก 10,000 ขั้น ตัวแทนทำตาม Ko และเก็บข้อมูล แล้วฝึก actor ด้วย cross-entropy กับการเลือกโหนดแม่ของ Ko (สูงสุด 20 รอบ หยุดเมื่อตรงกัน 90%) และ warm-start critic ด้วยผลตอบแทนจริงของ Ko จากนั้นฝึกด้วย MAPPO (clip 0.2, GAE $\lambda = 0.95$, rollout 1,000 ขั้น, 4 epoch, learning rate 3×10^{-4}) critic ส่วนกลางเห็นสถานะของโหนดกับค่าเฉลี่ยของทุกโหนด และใช้เฉพาะตอนฝึก ระหว่างฝึกเก็บค่าเฉลี่ยเคลื่อนที่ของน้ำหนัก และทุก 10,000 ขั้นประเมินด้วยคะแนนรวมเทียบ Ko บน topology validation เพื่อเลือก checkpoint ที่ดีที่สุด

4.2.5 การทำงานแบบกระจายศูนย์ขณะใช้งาน

(1) การถอดรหัสช่องแบบลำดับ โหนดแม่ตัดสินใจก่อนลูก แต่ละโหนดเลือกช่องคะแนนสูงสุดที่เพื่อนบ้านที่รบกวนและตัดสินใจไปแล้วยังไม่ใช้ เพื่อแก้ปัญหาที่ทุกโหนดเลือกช่องเดียวกันเมื่อเห็นสถานะคล้ายกัน ต้องใช้การประสานหนึ่งรอบเช่นเดียวกับ Ko และทุกวิธีที่เรียนรู้ใช้ตัวถอดรหัสเดียวกัน

(2) Switch hysteresis เพิ่มค่า m ให้ logit ของโหนดแม่และช่องปัจจุบันก่อนเลือกค่าสูงสุด โหนดจะสลับเมื่อทางเลือกใหม่ดีกว่าเกิน m เท่านั้น ไม่เปลี่ยนการฝึก m เลือกจาก {0, 0.5, 1, 2, 3, 4} บน validation ด้วยกติกา worst-case คือเลือก margin ที่คะแนนรวมต่ำสุดเทียบคู่เทียบใดๆ สูงที่สุด ได้ m = 2

(3) Safe fallback โหนดที่ entropy ของนโยบายเกิน 2 nats ใช้การกระทำของ Ko แทน โดยคำนวณหลังเพิ่ม hysteresis และใช้เฉพาะหัวของโหนดเอง

4.3 สภาพแวดล้อมการทดลองและการกำหนดพารามิเตอร์

พารามิเตอร์ของสภาพแวดล้อมแสดงในตารางที่ 3 ค่าพารามิเตอร์ของ EGAT-MAPPO แสดงในตารางที่ 4 และสถานการณ์ทดสอบแสดงในตารางที่ 5

ตารางที่ 3 พารามิเตอร์ของสภาพแวดล้อมจำลอง

พารามิเตอร์	ค่า
จำนวนโหนด / gateway	20 / 2 (ทดสอบเพิ่ม 50, 80 โหนด และ 4 gateway)
พื้นที่	สี่เหลี่ยมด้าน 30√n เมตร (B3: 37.5√n), grid ระยะ 35 เมตร (B4)
เกณฑ์ลิงก์ / การรบกวน	−76 dBm / −82 dBm
กำลังส่ง / noise / path loss	20 dBm / −94 dBm / log-distance exponent 3
PHY	802.11ax, 20 MHz, 1 SS, MCS 8.6–143.4 Mb/s
ช่อง downlink	6 ช่อง (6, 11, 36, 40, 44, 48)
ขั้นเวลา / ความยาว episode	100 ms / 200 ขั้น (20 วินาที)
ทราฟฟิก	on/off Markov (คงสถานะ 0.9) อัตราเอ็กซ์โพเนนเชียล
ต้นทุนการสลับ	หยุดใช้ลิงก์ 1 ขั้น และสูญเสียคิวใน setting (a)
ค่าปรับใน reward	สลับช่อง 0.1, เปลี่ยนโหนดแม่ 0.05, หาเส้นทางไม่ได้ 0.1

ตารางที่ 4 ค่าพารามิเตอร์ของ EGAT-MAPPO

กลุ่ม	พารามิเตอร์	ค่า
เครือข่าย	ขนาดซ่อน / หัว attention / ชั้น	64 / 4 / 2 (ไม่มี GRU)
เครือข่าย	ช่วงตัดสินใจช่อง t_c	10 ขั้น
MAPPO	learning rate / γ / GAE λ	3×10^{-4} / 0.98 / 0.95
MAPPO	clip / epoch / rollout / minibatch	0.2 / 4 / 1,000 / 50
MAPPO	entropy / value coef. / grad clip	0.01 / 0.5 / 0.5
BC	จำนวนขั้น / epoch สูงสุด / learning rate	10,000 / 20 / 10^{-3}
Reward	λ (เริ่ม → สิ้นสุด)	0.5 → 0.1
การฝึก	งบขั้นเวลา / ค่าเมล็ดสุ่ม	100,000 / 5
การใช้งาน	hysteresis margin / fallback entropy	2 / 2 nats

ตารางที่ 5 สถานการณ์ทดสอบ (ภาระเฉลี่ย 6 Mb/s ต่อโหนด n = 20 และ 2 gateway ถ้าไม่ระบุ)

สถานการณ์	เงื่อนไข
S1 / S2	ภาระต่ำ 2 Mb/s / ภาระสูง 10 Mb/s
S3	Hotspot: โหนดใกล้ gateway หนึ่งมีความต้องการ 3 เท่า
S4	สัญญาณรบกวนภายนอกบนช่องหนึ่ง ขั้น 50–150
S5	ภาระเปลี่ยนที่ขั้น 100: ครึ่งหนึ่งของโหนดเพิ่ม 3 เท่า
S6	relay ที่มี degree สูงสุดล้มที่ขั้น 100
B1	Hotspot เคลื่อนที่ทุก 40 ขั้น
B2	ภาระเป็นคาบ $1 + 0.8 \cdot \sin(2\pi t/60)$
B3	Topology เบาบาง (ระยะ 37.5 เมตร)
B4	Topology แบบ grid ที่ไม่เคยเห็นตอนฝึก
B5	สลับกลุ่มภาระสูงทุก 25 ขั้น
C1 / C2	ภาระต่ำมาก 1 Mb/s / ทราฟฟิกคงที่ตลอด
C3 / C4	เครือข่ายใหญ่ 50 / 80 โหนด ภาระ 10 Mb/s
C5	4 gateway

4.4 ผลการทดลองหลัก

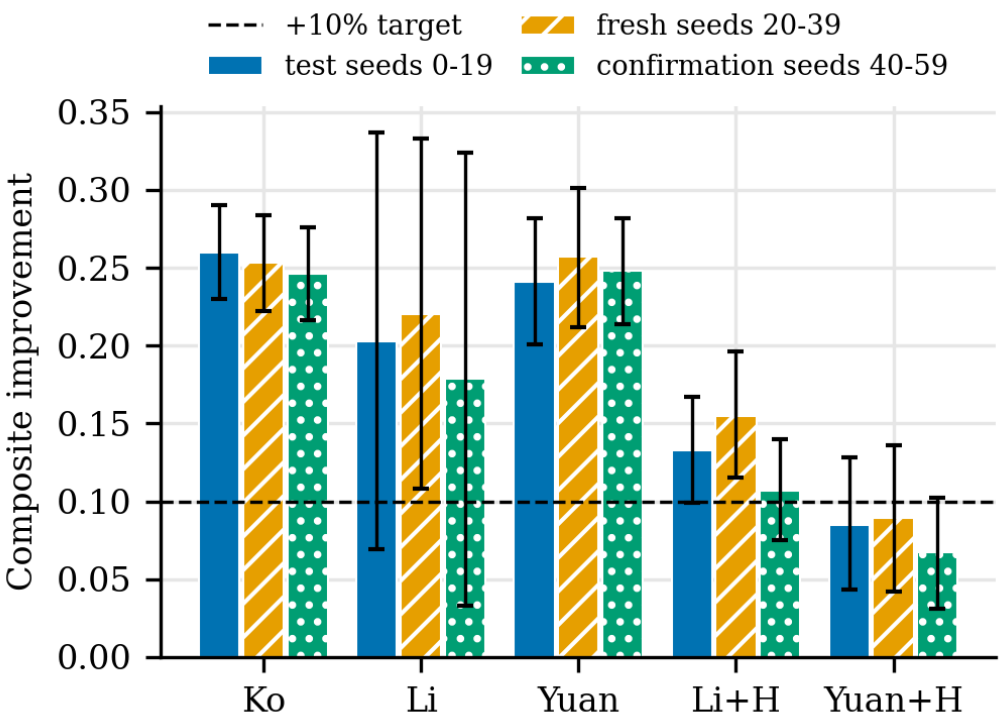
4.4.1 ผลเปรียบเทียบกับคู่เทียบ

ตารางที่ 6 เปรียบเทียบ EGAT-MAPPO ที่มี hysteresis (EGAT+H) กับคู่เทียบที่ดัดแปลงจากงานเผยแพร่ ใน setting (a) บน A+B และ topology ทดสอบ 0–19 ผลบน topology ยืนยันซึ่งใช้อ้างอิงหลักอยู่ในหัวข้อ 4.4.4

ตารางที่ 6 คะแนนรวมของ EGAT+H เทียบคู่เทียบ (setting a, A+B, ค่าเมล็ดสุ่มทดสอบ 0–19)

คู่เทียบ	ค่าเฉลี่ยรวม	ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม [95% CI]	สถานการณ์ที่ดีกว่า (Wilcoxon / bootstrap)	ต่ำสุดเมื่อปรับน้ำหนัก ±50%
Ko	+26.0%	+26.0% [+23.0%, +29.0%]	100% / 100%	+20.6%
Li (GAT-A2C)	+25.8%	+20.3% [+6.9%, +33.7%]	100% / 100%	+22.1%
Yuan (GAT+DQN)	+24.4%	+24.1% [+20.1%, +28.2%]	100% / 100%	+19.5%
M0	+31.2%	+31.1% [+29.1%, +33.1%]	91% / 91%	+22.0%
Q-neutral	+73.5%	+73.6% [+72.6%, +74.6%]	100% / 100%	+65.6%

ใน setting (a) บน topology 0–19 EGAT+H ผ่านเกณฑ์ที่กำหนดไว้ครบ 4 ข้อเทียบทุกคู่เทียบ (1) คะแนนรวมเฉลี่ยเกิน +10% โดยต่ำสุดคือ Li +20.3% (2) ดีกว่าอย่างมีนัยสำคัญอย่างน้อย 91% ของสถานการณ์ (3) ดีกว่า Ko ทุกสถานการณ์ ต่ำสุดคือ S1 +13.4% และ (4) ยังเกิน +10% เมื่อปรับน้ำหนักทุกแบบ (ต่ำสุด Yuan +19.5%) ช่วงความเชื่อมั่นไม่คร่อม 0 ทุกวิธี ช่วงเทียบ Li กว้างที่สุด (+6.9% ถึง +33.7%) เพราะ Li แปรปรวนมากระหว่างค่าเมล็ดสุ่มการฝึก โดยค่าเมล็ดสุ่ม 4 ฝึกได้ไม่ดี topology ชุดนี้ถูกใช้ในการเลือกโครงสร้างที่ไม่มี GRU จึงใช้ผลบน topology ยืนยันในหัวข้อ 4.4.4 เป็นหลัก ผลแยกตามชุด topology และ setting สรุปในตารางที่ 12



ภาพที่ 2 คะแนนรวมของ EGAT+H เทียบคู่เทียบ พร้อมช่วงความเชื่อมั่น 95% บน topology ทดสอบ 0–19 topology ใหม่ 20–39 และ topology ยืนยัน 40–59 (เส้นประคือเป้าหมาย +10%)

4.4.2 ที่มาของผลรายตัวชี้วัด

ตารางที่ 7 แยกคะแนนรวมออกเป็นส่วนของแต่ละตัวชี้วัด เทียบ Ko คะแนน +13.9% จาก +26.0% มาจากความเสถียร เพราะ EGAT+H สลับ 42 ครั้งต่อ episode ขณะที่ Ko สลับ 616 ครั้ง ส่วนที่เหลือ +12.1% มาจากอัตราสูญเสียที่ต่ำกว่า (+7.3%) throughput ที่สูงกว่า (+2.8%) และ p5 (+1.7%) ส่วน Jain ใกล้เคียงกัน เทียบ Li+H และ Yuan+H ซึ่งสลับพอๆ กัน (43 ครั้ง) ส่วนของความเสถียรเกือบเป็น 0 และข้อได้เปรียบทั้งหมดมาจากอัตราสูญเสีย p5 และ throughput ข้อได้เปรียบของ EGAT+H จึงไม่ได้มาจากการสลับน้อยเพียงอย่างเดียว ผลรวมในตารางนี้คิดจากค่าเฉลี่ยรวมทุก run ส่วนตารางที่ 6 และ 9 ใช้ค่าเฉลี่ยของคู่ค่าเมล็ดสุ่ม ซึ่งเป็นค่าที่ใช้อ้างอิง ทั้งสองแบบต่างกันไม่เกิน 0.9% ยกเว้น Li ที่แปรปรวนสูง ระหว่างค่าเมล็ดสุ่ม (+25.8% เทียบ +20.3%)

ตารางที่ 7 ส่วนของคะแนนรวมจากแต่ละตัวชี้วัด (setting a, A+B, ค่าเมล็ดสุ่ม 0–19)

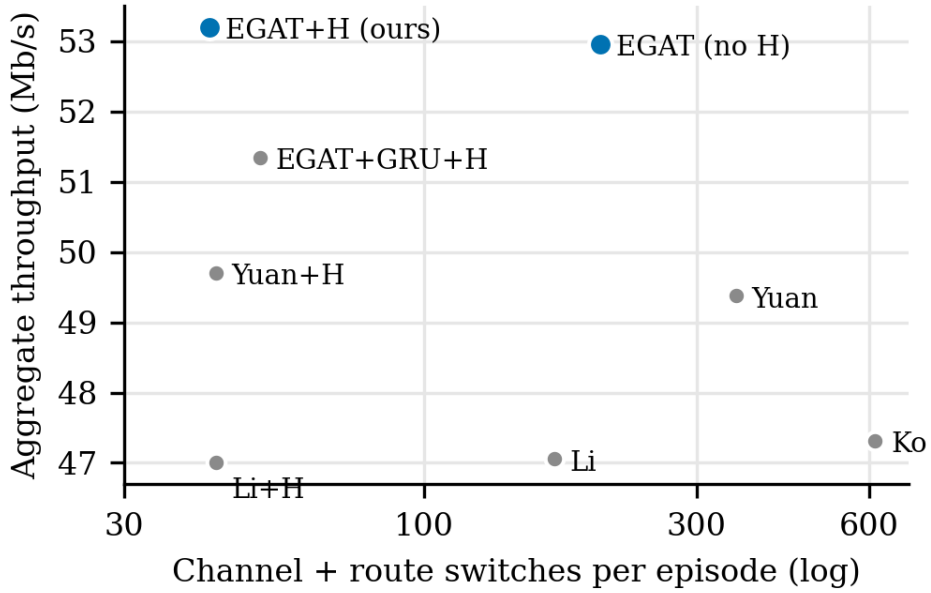
คู่เทียบ	Throughput	Jain	p5	สูญเสีย	เสถียร	รวม
Ko	+2.8%	+0.2%	+1.7%	+7.3%	+13.9%	+26.0%
Li	+3.0%	−0.1%	+5.0%	+7.3%	+10.7%	+25.8%
Yuan	+1.8%	+0.5%	+3.5%	+6.1%	+12.6%	+24.4%
Li+H	+3.0%	−0.4%	+3.9%	+6.8%	+0.3%	+13.6%
Yuan+H	+1.6%	−0.0%	+2.4%	+5.0%	+0.4%	+9.4%
EGAT+GRU+H	+0.8%	−0.1%	+1.2%	+3.0%	+2.7%	+7.6%

ตารางที่ 8 แสดงค่าจริงของตัวชี้วัด EGAT+H มี throughput รวมสูงกว่า Ko 12.4% (53.2 เทียบ 47.3 Mb/s) p5 สูงกว่า 8.7% อัตราสูญเสียลดจาก 0.248 เหลือ 0.172 และมีอันดับเฉลี่ยห้าตัวชี้วัดดีที่สุด (2.29 รองลงมาคือแบบที่มี GRU 3.58 และ Yuan+H 4.15) เทียบแบบที่มี GRU แบบที่ไม่มี GRU ได้ throughput สูงกว่า 3.6% อัตราสูญเสียต่ำกว่า และสลับน้อยกว่า (42 เทียบ 52 ครั้ง) Q-neutral ส่งทราฟฟิกได้แทบไม่มี (0.17 Mb/s) จึงไม่แสดงในตาราง คอลัมน์สุดท้ายของตารางที่ 8 แสดงคะแนนรวมที่ EGAT+H ดีกว่าแต่ละวิธีโดยตรง ซึ่งเป็นค่าเดียวกับตารางที่ 6 และ 9 ส่วนค่าของแต่ละตัวชี้วัดในตารางเป็นค่าจริง ไม่ใช่คะแนน

ตารางที่ 8 ค่าเฉลี่ยของตัวชี้วัด และคะแนนรวมที่ EGAT+H ดีกว่าแต่ละวิธี (setting a, A+B, ค่าเมล็ดสุ่ม 0–19)

วิธี	Throughput (Mb/s)	Jain	p5 (Mb/s)	อัตราสูญเสีย	การสลับ / episode	EGAT+H ดีกว่า (คะแนนรวม)
M0	26.87	0.893	0.858	0.516	0.2	+31.1%
Ko	47.32	0.777	1.410	0.248	615.5	+26.0%
Li	47.06	0.790	1.220	0.245	169.1	+20.3%
Yuan	49.38	0.767	1.296	0.221	351.5	+24.1%
Li+H	47.00	0.802	1.278	0.244	43.3	+13.3%
Yuan+H	49.70	0.787	1.362	0.213	43.3	+8.5%
EGAT+GRU+H (รุ่นเดิม)	51.35	0.788	1.442	0.193	51.7	+6.9%
EGAT+H (งานนี้)	**53.20**	**0.786**	**1.533**	**0.172**	**42.2**	**—**

ภาพที่ 3 แสดง throughput เทียบจำนวนการสลับของแต่ละวิธี EGAT ที่ไม่มี hysteresis ได้ 53.0 Mb/s และสลับราว 204 ครั้ง เมื่อใช้ margin 2 ได้ 53.2 Mb/s และสลับ 42 ครั้ง hysteresis จึงลดการสลับลงเกือบ 5 เท่าโดยไม่เสีย throughput บนชุดเดียวกัน EGAT ที่ไม่มี hysteresis ดีกว่า Ko +21.5% [+19.2%, +23.7%] อยู่แล้ว แต่ส่วนต่างเหนือ Li และ Yuan ส่วนใหญ่ต้องอาศัย hysteresis แบบที่มี GRU (EGAT+GRU+H) อยู่ต่ำกว่าทั้งด้าน throughput และการสลับ



ภาพที่ 3 Throughput รวมเทียบจำนวนการสลับต่อ episode (สเกล log) ของแต่ละวิธี เฉลี่ย A+B setting (a) topology 0–19 แกน y ไม่ได้เริ่มที่ 0

4.4.3 ความเป็นธรรมของการเปรียบเทียบ: ให้คู่เทียบใช้ hysteresis

Hysteresis เป็นกฎการถอดรหัสที่ใช้กับนโยบายใดก็ได้ จึงใส่ให้ Li และ Yuan ด้วยกติกาเลือก margin เดียวกัน ได้ margin 1 ทั้งสองวิธี ผลเทียบแสดงในตารางที่ 9

ตารางที่ 9 EGAT+H เทียบคู่เทียบที่มี hysteresis (setting a, A+B, ค่าเมล็ดสุ่ม 0–19)

คู่เทียบ	**ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม [95% CI]**	**สถานการณ์ที่ดีกว่า (Wilcoxon / bootstrap)**	**ต่ำสุดเมื่อปรับน้ำหนัก ±50%**
Li+H	+13.3% [+9.9%, +16.7%]	91% / 91%	+11.4%
Yuan+H	+8.5% [+4.3%, +12.8%]	91% / 100%	+7.6%

EGAT+H ดีกว่าทั้ง Li+H และ Yuan+H อย่างมีนัยสำคัญ เทียบ Li+H เกินเกณฑ์ +10% (+13.3%) ส่วนเทียบ Yuan+H ได้ +8.5% ซึ่งเกิน 5% แต่ยังไม่ถึง 10% ตามตารางที่ 7 ทั้งสามวิธีสลับใกล้เคียงกัน (42–43 ครั้งต่อ episode) ส่วนของความเสถียรจึงเกือบเป็น 0 ข้อได้เปรียบเหนือ Yuan+H มาจากอัตราสูญเสีย (+5.0%) p5 (+2.4%) และ throughput (+1.6%) คือมาจากคุณภาพของการเลือกช่องและเส้นทาง ไม่ใช่จากการสลับน้อย แบบที่มี GRU ในรอบก่อนเสมอกับ Yuan+H (+0.7% ช่วงคร่อม 0) การตัด GRU จึงเป็นสิ่งที่ทำให้วัดข้อได้เปรียบของสถาปัตยกรรมเหนือ GAT ของงานเดิมได้

4.4.4 การยืนยันบน topology ใหม่

เนื่องจาก topology ทดสอบ 0–19 ถูกใช้แล้วตอนพัฒนา hysteresis และตอนเลือกตัด GRU จึงประเมินทุกโมเดลอีกครั้งบน topology ใหม่สองชุด ชุดละ 20 topology ต่อสถานการณ์ ชุดแรก (ค่าเมล็ดสุ่ม 20–39) เคยใช้ยืนยันแบบที่มี

GRU มาก่อน ส่วนชุดที่สอง (40–59) เป็นชุดยืนยันตามโปรโตคอลในหัวข้อ 3.4 ซึ่งไม่เคยใช้ในการทดลองใดก่อนรัน ผลแสดงในตารางที่ 10 และภาพที่ 2

ตารางที่ 10 EGAT+H บน topology ใหม่ (setting a, A+B, ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม [95% CI])

คู่เทียบ	topology 20–39	topology ยืนยัน 40–59	สถานการณ์ที่ดีกว่า 40–59 (Wilcoxon / bootstrap)	ต่ำสุดเมื่อปรับน้ำหนัก ±50% (40–59)
Ko	+25.3% [+22.2%, +28.4%]	+24.6% [+21.6%, +27.6%]	100% / 100%	+19.1%
Li	+22.0% [+10.8%, +33.3%]	+17.9% [+3.3%, +32.4%]	91% / 100%	+21.4%
Yuan	+25.7% [+21.2%, +30.1%]	+24.8% [+21.4%, +28.2%]	100% / 100%	+20.4%
M0	+29.7% [+27.0%, +32.5%]	+31.6% [+30.0%, +33.2%]	91% / 91%	+22.6%
Q-neutral	+73.5% [+72.3%, +74.7%]	+73.7% [+72.6%, +74.9%]	100% / 100%	+65.6%
Li+H	+15.5% [+11.5%, +19.6%]	+10.7% [+7.5%, +14.0%]	82% / 82%	+8.6%
Yuan+H	+8.9% [+4.2%, +13.6%]	+6.7% [+3.1%, +10.2%]	91% / 100%	+5.5%
EGAT+GRU+H	+4.0% [−1.2%, +9.1%]	+4.9% [+0.7%, +9.1%]	73% / 73%	+4.7%

ผลบนทั้งสองชุดสอดคล้องกับชุดทดสอบ บน topology ยืนยัน 40–59 EGAT+H ดีกว่าคู่เทียบที่ดัดแปลงจากงานเผยแพร่ทุกวิธีเกิน 10% และช่วงความเชื่อมั่นไม่คร่อม 0 ทุกวิธี ไม่มีสถานการณ์ใดแพ้ Ko (ต่ำสุด S1 +13.2%) และผ่านการปรับน้ำหนักทุกแบบ จึงผ่านเกณฑ์ 4 ข้อ (P3) เทียบ Yuan+H ได้ +6.7% และขอบล่าง +3.1% ผ่านเกณฑ์ P1 และขอบล่างเทียบ Ko, Li, Yuan, M0, Q-neutral และ Li+H เกิน 0 ทุกวิธี ผ่านเกณฑ์ P2 ตามโปรโตคอลจึงใช้แบบที่ไม่มี GRU เป็นแบบจำลองหลัก บน topology 20–39 ผลไปทางเดียวกัน (Ko +25.3%, Yuan+H +8.9%) ส่วนเทียบแบบที่มี GRU ดีกว่าบนทุกชุด แต่บน 20–39 ช่วงคร่อม 0 (+4.0%) ข้อได้เปรียบเหนือ Yuan+H เกิน 5% บนทุกชุด แต่ยังไม่ถึง 10% และไม่ทนการปรับน้ำหนักที่ระดับ 10%

4.4.5 สถานการณ์ที่ยากและเครือข่ายขนาดใหญ่ (กลุ่ม C)

แบบจำลองฝึกบน 20 โหนดเท่านั้น ใน setting (a) EGAT+H ดีกว่า Ko เฉลี่ย +33.6% บนกลุ่ม C ข้อได้เปรียบเพิ่มตามขนาดเครือข่าย คือ +46.5% ที่ 50 โหนด และ +46.9% ที่ 80 โหนด ส่วนที่ภาระต่ำมาก (C1) ได้น้อยที่สุด +12.1% เพราะเกือบทุกวิธีส่งทราฟฟิกได้ครบ เทียบ Li+H และ Yuan+H เฉลี่ย +5.9% และ +8.7% ที่ 80 โหนด EGAT+H สลับ 244 ครั้งต่อ episode ขณะที่ Yuan+H สลับ 860 ครั้ง และ Ko สลับ 3,879 ครั้ง

4.4.6 การตัดองค์ประกอบของแบบจำลอง

ฝึก EGAT ใหม่โดยตัดองค์ประกอบทีละส่วน ส่วนละ 3 ค่าเมล็ดสุ่ม และประเมินด้วย margin 2 เดียวกับแบบเต็มที่มี GRU (EGAT+GRU+H) บน topology ทดสอบ 0–19 ผลแสดงในตารางที่ 11

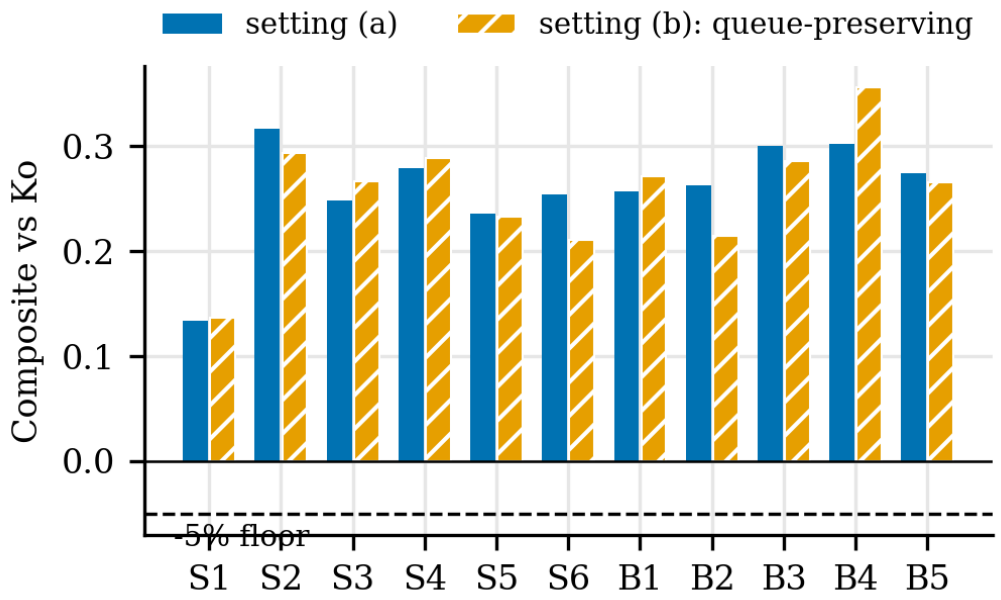
ตารางที่ 11 การตัดองค์ประกอบของแบบที่มี GRU (setting a, A+B, 3 ค่าเมล็ดสุ่มต่อแบบ, ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม)

แบบ	**เทียบ Ko**	**เทียบ Li+H**	**เทียบ Yuan+H**	**เทียบ EGAT+GRU+H [95% CI]**
EGAT+GRU+H (seed 0–2)	+22.6%	+5.5%	+0.6%	—
ตัดคุณลักษณะของขอบ	+24.9%	+9.6%	+4.4%	+3.0% [−5.5%, +11.6%]
ตัด GRU (แบบหลักปัจจุบัน)	+26.0%	+13.3%	+8.7%	+7.0% [−1.1%, +15.1%]
ตัด Ko prior	+17.3%	+3.5%	−1.9%	−4.6% [−14.1%, +4.8%]
ตัด BC จาก Ko	+22.0%	+6.8%	+1.4%	+0.1% [−8.2%, +8.4%]

ช่วงความเชื่อมั่นของทุกความต่างเทียบแบบเต็มคร่อม 0 จึงสรุปได้เพียงเป็นแนวโน้ม การตัด Ko prior ทำให้แย่ลงมากที่สุด (−4.6%) ส่วน BC ไม่มีผลที่วัดได้ ข้อที่ขัดกับการออกแบบคือการตัด GRU (+7.0%) และคุณลักษณะของขอบ (+3.0%) กลับทำให้ดีขึ้น แบบที่ตัด GRU ดีกว่า Yuan+H +8.7% [+4.8%, +12.5%] อย่างมีนัยสำคัญ ซึ่งแบบเต็มทำไม่ได้ เนื่องจากผลนี้ได้มาหลังเห็นชุดทดสอบ จึงยืนยันด้วยโปรโตคอลที่กำหนดไว้ก่อนรันบน topology ใหม่ 40–59 (หัวข้อ 3.4) ซึ่งผ่านเกณฑ์ (หัวข้อ 4.4.4) แบบที่ไม่มี GRU จึงเป็นแบบจำลองหลัก เมื่อฝึกครบ 5 ค่าเมล็ดสุ่ม แบบที่ไม่มี GRU ดีกว่าแบบที่มี GRU +6.9% [+2.6, +11.3] บน topology 0–19 และ +4.9% [+0.7, +9.1] บน topology 40–59 ผลชี้ว่าความรู้จาก Ko เป็นองค์ประกอบที่ช่วยมากที่สุด GRU ไม่ช่วยและอาจทำให้แย่ลง เป็นไปได้ว่าเพราะ observation ของแต่ละขั้นมีข้อมูลเพียงพอแล้ว และ GRU ทำให้การฝึกด้วยงบ 100,000 ขั้นยากขึ้น ส่วนคุณลักษณะของขอบยังไม่มีหลักฐานว่าช่วย setting (b) ให้ผลไปทางเดียวกัน

4.5 ผลใน **setting** ที่เก็บคิวระหว่างสลับ (**b**)

เมื่อทุกวิธีเก็บคิวไว้ระหว่างสลับได้ การสลับมีต้นทุนต่ำลง แต่ผลแทบไม่เปลี่ยน บน topology ทดสอบ 0–19 EGAT+H ดีกว่า Ko +25.7% [+22.4%, +29.0%] ดีกว่า Li +19.8% [+7.8%, +31.8%] และดีกว่า Yuan +22.1% [+18.1%, +26.1%] บน topology 20–39 และ 40–59 ดีกว่า Ko +25.8% [+22.5%, +29.2%] และ +24.3% [+21.1%, +27.6%] เทียบ Li+H ดีกว่า +13.3% (20–39 +15.6%, 40–59 +10.8%) และเทียบ Yuan+H ดีกว่า +8.3% [+3.8%, +12.8%] (20–39 +8.8%, 40–59 +6.5% [+2.8%, +10.1%]) อย่างมีนัยสำคัญทุกชุด ภาพที่ 4 แสดงผลรายสถานการณ์



ภาพที่ 4 คะแนนรวมของ EGAT+H เทียบ Ko รายสถานการณ์ ใน setting (a) และ (b) (เส้นประคือขอบเขต −5% ของเกณฑ์ข้อ 3)

ไม่มีสถานการณ์ใดแพ้ Ko ในทั้งสอง setting และทั้งสามชุด topology ต่ำสุดคือ S1 (ภาระต่ำ) +13.2% ถึง +14.5% ซึ่งทุกวิธีส่งทราฟฟิกได้เกือบครบ ข้อได้เปรียบจึงมาจากความเสถียรเป็นหลัก ในรอบก่อนปรับเทียบ แบบที่มี GRU แพ้ Ko ใน B4 (topology แบบ grid) เมื่อเก็บคิวระหว่างสลับได้ ในรอบนี้ B4 ดีกว่า Ko +30.2% ใน setting (a) และ +35.6% ใน setting (b) จึงเป็นไปได้ว่าปัญหาเดิมมาจากแบบจำลอง airtime รุ่นแรกที่ให้ Ko ได้เปรียบใน grid

ตารางที่ 12 สรุปผลตามเกณฑ์ 4 ข้อแยกตาม setting และชุด topology เทียบคู่เทียบที่ดัดแปลงจากงานเผยแพร่ เกณฑ์ผ่านครบทั้ง 6 ชุด

ตารางที่ 12 ผลตามเกณฑ์ที่กำหนดไว้ แยกตาม setting และชุด topology (เทียบคู่เทียบที่ดัดแปลงจากงานเผยแพร่)

Setting / topology	(1) เฉลี่ย ≥ +10%	(2) นัยสำคัญ ≥ 60%	(3) ไม่แพ้ Ko เกิน 5%	(4) ทนการปรับน้ำหนัก
(a) / 0–19	ผ่าน (ต่ำสุด Li +20.3%)	ผ่าน (≥ 91%)	ผ่าน (ต่ำสุด S1 +13.4%)	ผ่าน (ต่ำสุด Yuan +19.5%)
(a) / ใหม่ 20–39	ผ่าน (ต่ำสุด Li +22.0%)	ผ่าน (≥ 91%)	ผ่าน (ต่ำสุด S1 +14.3%)	ผ่าน (ต่ำสุด Ko +19.8%)
(a) / ยืนยัน 40–59	ผ่าน (ต่ำสุด Li +17.9%)	ผ่าน (≥ 91%)	ผ่าน (ต่ำสุด S1 +13.2%)	ผ่าน (ต่ำสุด Ko +19.1%)
(b) / 0–19	ผ่าน (ต่ำสุด Li +19.8%)	ผ่าน (≥ 91%)	ผ่าน (ต่ำสุด S1 +13.7%)	ผ่าน (ต่ำสุด Yuan +17.3%)
(b) / ใหม่ 20–39	ผ่าน (ต่ำสุด Li +21.7%)	ผ่าน (≥ 91%)	ผ่าน (ต่ำสุด S1 +14.5%)	ผ่าน (ต่ำสุด Yuan +19.6%)
(b) / ยืนยัน 40–59	ผ่าน (ต่ำสุด Li +17.5%)	ผ่าน (≥ 91%)	ผ่าน (ต่ำสุด S1 +13.6%)	ผ่าน (ต่ำสุด Ko +18.8%)

4.6 การปรับเทียบและยืนยันผลบน **ns-3**

เพื่อตรวจว่าผลไม่ได้เกิดจากข้อสมมติของสภาพแวดล้อมระดับ flow จึงนำนโยบายที่ฝึกแล้วไปทำงานบน ns-3.47 ระดับแพ็กเก็ตโดยไม่ฝึกใหม่ Python ยังเป็นผู้สร้าง topology ทราฟฟิก และรันนโยบายทุกวิธีด้วยค่าเมล็ดสุ่มเดียวกัน ส่วน ns-3 รับการกระทำทุกขั้นเวลา 100 ms แล้วส่งแพ็กเก็ตจริงผ่าน MAC/PHY ของ 802.11ax (20 MHz, 1 SS, A-MPDU, IdealWifiManager) ด้วย path loss เดียวกับสภาพแวดล้อมจำลอง การสลับช่องและเส้นทางมีช่วงหยุดส่งและการทิ้งคิวแบบเดียวกับ setting (a) ใช้ RTS/CTS เป็นค่าหลัก และรันซ้ำโดยไม่ใช้ RTS/CTS เพื่อดูความไวต่อการตั้งค่า MAC สถานการณ์ที่ใช้คือ S2 (ภาระสูง) B1 (hotspot เคลื่อนที่) และ B3 (topology เบาบาง) ค่าเมล็ดสุ่มทดสอบ 0–4 สถานการณ์และ setting ถูกกำหนดก่อนเห็นผลบน ns-3

การปรับเทียบใช้การเล่นซ้ำแบบ open loop คือส่งการกระทำและความต้องการชุดเดียวกับที่ใช้ในสภาพแวดล้อมจำลองเข้า ns-3 แล้วเทียบ throughput รวม แบบจำลอง airtime รุ่นแรกที่แบ่ง airtime เท่ากันตามจำนวนลิงก์ (1/k) คลาดจาก ns-3 เฉลี่ย 23.5% (rms) และคลาดมากที่สุดกับนโยบายที่รวมทราฟฟิกไว้บนช่องเดียว (EGAT+H, Li, Yuan ใน S2 สูงเกินจริง 22–28%) ขณะที่ Ko ซึ่งกระจายช่องคลาดเพียง 3% ความคลาดเพิ่มตามภาระ จึงเปลี่ยนเป็นแบบจำลองโดเมนการรบกวน (หัวข้อ 4.1.1) และปรับ η บน S2 และ B3 ได้ $\eta = 0.65$ ความคลาด rms 7.4% (มากสุด 11.4%) และบน B1 ซึ่งไม่ได้ใช้ปรับ ได้ rms 7.0% (มากสุด 10.0%) ลำดับของวิธีตรงกับ ns-3 ทั้งสามสถานการณ์ ความคลาดที่เหลือส่วนใหญ่คือ

แบบจำลองให้ throughput ของ Ko ต่ำกว่า ns-3 ราว 10% ซึ่งทำให้ผลเทียบ Ko ในสภาพแวดล้อมจำลองเข้าข้างวิธีของเราเล็กน้อย

จากนั้นฝึกทุกวิธีที่เรียนรู้ใหม่ในสภาพแวดล้อมที่ปรับเทียบแล้ว ด้วยสูตรการฝึกและกติกาเลือก checkpoint เดิม ผลในหัวข้อ 4.4–4.5 ทั้งหมดมาจากรอบนี้ แล้วนำ checkpoint ชุดเดียวกันไปรันบน ns-3 ตารางที่ 13 เปรียบเทียบคะแนนรวมของ EGAT+H บน S2, B1 และ B3 ระหว่างสภาพแวดล้อมจำลองกับ ns-3

ตารางที่ 13 คะแนนรวมของ EGAT+H เทียบคู่เทียบ บนสภาพแวดล้อมจำลองและ ns-3 (setting a, S2/B1/B3, ค่าเฉลี่ยคู่ค่าเมล็ดสุ่ม [95% CI])

คู่เทียบ	สภาพแวดล้อมจำลอง	ns-3 (RTS/CTS)	ns-3 (ไม่ใช้ RTS/CTS)
Ko	+29.1% [+26.3, +32.0]	+23.1% [+15.5, +30.7]	+21.8% [+14.4, +29.2]
Li (GAT-A2C)	+24.6% [+8.7, +40.4]	+43.7% [+35.1, +52.2]	+46.1% [+37.9, +54.3]
Yuan (GAT+DQN)	+27.8% [+22.8, +32.8]	+36.4% [+22.3, +50.4]	+37.2% [+22.6, +51.9]
M0	+36.3% [+34.6, +38.0]	+52.6% [+48.6, +56.5]	+55.5% [+52.3, +58.6]
Q-neutral	+72.2% [+71.4, +73.1]	+69.3% [+68.2, +70.4]	+68.0% [+67.0, +69.0]
Li+H	+16.5% [+12.3, +20.7]	+36.5% [+32.2, +40.8]	+39.5% [+35.7, +43.4]
Yuan+H	+9.0% [+4.6, +13.3]	+16.4% [+0.4, +32.5]	+18.4% [+2.1, +34.6]
EGAT+GRU+H	+8.1% [+2.9, +13.2]	+15.3% [+1.8, +28.8]	+17.7% [+4.4, +30.9]

คอลัมน์สภาพแวดล้อมจำลองใช้ topology ทดสอบ 0–19 ส่วน ns-3 ใช้ 0–4 ช่วงความเชื่อมั่นบน ns-3 จึงกว้างกว่าบน ns-3 EGAT+H ดีกว่าทุกวิธีอย่างมีนัยสำคัญทั้งสองการตั้งค่า MAC รวมทั้ง Ko (+23.1% และ +21.8%) และ Yuan+H (+16.4% และ +18.4%) ซึ่งแบบที่มี GRU ทำไม่ได้ (Ko +10.7% และ +7.2%, Yuan+H +2.3% และ +1.8% ทั้งหมดคร่อม 0) แต่ขอบล่างเทียบ Yuan+H อยู่ใกล้ 0 (+0.4% และ +2.1%) เพราะมีเพียง 5 topology และใน B3 ส่วนต่างเหนือ Yuan+H เหลือ +7.1% รายสถานการณ์ (RTS/CTS) EGAT+H ดีกว่า Ko ทุกสถานการณ์ (S2 +14.1%, B1 +18.1%, B3 +37.0%) throughput สูงกว่าหรือเท่ากับ Ko (S2 68.1 เทียบ 67.1, B1 66.4 เทียบ 66.1, B3 49.8 เทียบ 43.6 Mb/s) อัตราสูญเสียต่ำกว่า และสลับน้อยกว่าราว 18 เท่า (45 เทียบ 790 ครั้งต่อ episode) แบบที่มี GRU ได้ throughput ต่ำกว่า Ko ใน S2 และ B1 (62.3 และ 61.2 Mb/s) แบบที่ไม่มี GRU จึงปิดจุดอ่อนนี้ได้ ข้อยกเว้นคือเมื่อไม่ใช้ RTS/CTS ใน S2 Ko ยังได้ throughput สูงกว่า (66.4 เทียบ 63.8 Mb/s) และมี p5 ดีกว่า EGAT+H ชนะใน S2 นี้ +8.6% จากความเสถียรและอัตราสูญเสีย ผลเทียบ Ko ในสภาพแวดล้อมจำลองยังสูงกว่าบน ns-3 (+29.1% เทียบ +23.1%) เพราะแบบจำลองยังให้ throughput ของ Ko ต่ำกว่า ns-3 ราว 10% ส่วนผลเทียบ Li, Yuan และคู่เทียบที่มี hysteresis บน ns-3 กลับสูงกว่าในสภาพแวดล้อมจำลอง ns-3 เป็นผลประกอบที่ไม่ใช้ตัดสินตามโปรโตคอล แต่ให้ข้อสรุปไปทางเดียวกับสภาพแวดล้อมจำลอง

ก่อนปรับเทียบ แบบจำลองรุ่นแรกให้แบบที่มี GRU ดีกว่า Ko +21.2% ในสภาพแวดล้อมจำลอง แต่บน ns-3 เหลือ +1.5% [−11.5, +14.6] ซึ่งไม่มีนัยสำคัญ เพราะนโยบายที่ฝึกในแบบจำลองเดิมเรียนรู้ที่จะรวมทราฟฟิกไว้บนช่องเดียว ซึ่งแบบจำลองเดิมประเมินเกินจริง ผลนี้แสดงว่าการปรับเทียบสภาพแวดล้อมจำลองก่อนฝึกจำเป็นต่อการนำนโยบายไปใช้นอกสภาพแวดล้อมจำลอง

4.7 ผลระยะที่ 1: **GAT+RAES** บน **native ns-3** แบบ **single-hop**

ระยะที่ 1 พัฒนา GAT+RAES (GAT ร่วมกับ Risk-Aware Execution Selector ซึ่งเลือกช่องตามลำดับโดยถ่วงค่า Q กับความเสี่ยงการรบกวนและต้นทุนการสลับ) และรุ่น Hybrid ที่เพิ่ม conflict mask การจำกัดอิทธิพลของ Q และ actuation gate ประเมินด้วย native ns-3 บน 15 คู่ AP–STA แบบ single-hop และ 4 ช่อง ใน 5 สภาวะ stress × 5 โหลด × 2 ค่าเมล็ดสุ่ม ตัวชี้วัดหลักคือ satisfaction (SAT) ซึ่งเท่ากับทราฟฟิกที่ส่งได้หารด้วยความต้องการราย flow Hybrid ได้ SAT 61.773% และ goodput 99.532 Mbps เทียบ Raw 35.283% และ 58.836 Mbps สูงกว่า GA-Net [15] และ DGN [16] adaptations ทุก 50 กรณีที่จับคู่ และสูงกว่า BFS-CA-inspired [17] เฉลี่ย 5.122 จุดเปอร์เซ็นต์ ผลหลักแสดงในตารางที่ 14

ตารางที่ 14 ผลหลักของหกวิธีในระยะที่ 1 (native ns-3, single-hop) พร้อม Normal อ้างอิง

วิธี	Primary SAT %	Goodput Mbps	Normal SAT %
GAT+RAES raw	35.283	58.836	43.930
GAT+RAES Hybrid	61.773	99.532	68.735
Q-neutral	60.940	97.702	68.451
GA-Net raw	31.346	49.755	36.757
DGN raw	27.761	42.641	32.895
BFS-CA-inspired	56.651	94.413	67.960

ระยะที่ 1 มีข้อจำกัดสามข้อที่นำไปสู่ระยะที่ 2 (1) ส่วนเพิ่มเหนือ Q-neutral เพียง 0.833 จุดเปอร์เซ็นต์ จึงยืนยันไม่ได้ว่าตัวเรียนรู้ GAT เป็นสาเหตุหลักของผล (2) ใช้ค่าเมล็ดสุ่มที่เคยเห็นแล้วสองค่าและยังไม่มีนัยสำคัญทางสถิติ และ (3) เป็น single-hop ไม่มี relay หรือ routing จึงไม่ใช่ mesh จริง ระยะที่ 2 แก้ทั้งสามข้อด้วยการประเมินบน mesh หลาย hop ด้วยโปรโตคอลที่กำหนดไว้ล่วงหน้า หลายค่าเมล็ดสุ่มการฝึก topology ใหม่สำหรับยืนยัน และการตัดองค์ประกอบ โดยฝึกบนสภาพแวดล้อมจำลองระดับ flow ที่ปรับเทียบกับ ns-3 และยืนยันผลบน ns-3 (หัวข้อ 4.6)

บทที่ 5

บทสรุป

5.1 สรุปผลการดำเนินโครงงาน

ตามวัตถุประสงค์ 1.2.1–1.2.2 ได้กำหนดแบบจำลอง mesh หลาย hop ที่ตัดสินใจช่องและเส้นทางร่วมกัน พร้อมต้นทุนการสลับจริง และพัฒนา EGAT-MAPPO ที่รวม GATv2 ที่รับคุณลักษณะของขอบ หัวตัดสินใจสองช่วงเวลา (ไม่มีหน่วยความจำ GRU) residual prior จาก Ko, behaviour cloning, MAPPO และ switch hysteresis โดยทำงานแบบกระจายศูนย์ขณะใช้งาน

ตามวัตถุประสงค์ 1.2.3 ในสภาพแวดล้อมจำลองที่ปรับเทียบกับ ns-3 แล้ว ใน setting (a) บน topology ยืนยันที่กำหนดไว้ก่อนรัน (40–59) EGAT-MAPPO มีคะแนนรวมสูงกว่าคู่เทียบที่ดัดแปลงจากงานเผยแพร่ทุกวิธีเกิน 10% (Ko +24.6%, Li +17.9%, Yuan +24.8%, M0 +31.6%, Q-neutral +73.7%) และผ่านเกณฑ์ที่กำหนดไว้ครบ 4 ข้อ ทั้งบน topology ยืนยัน topology ทดสอบ (Ko +26.0%) topology ใหม่ 20–39 และใน setting (b) (ตารางที่ 12) บน ns-3 ใน 3 สถานการณ์ EGAT-MAPPO ดีกว่าทุกวิธีอย่างมีนัยสำคัญทั้งสองการตั้งค่า MAC โดยดีกว่า Ko +23.1% (RTS/CTS) และ +21.8% (ไม่ใช้ RTS/CTS)

ตามวัตถุประสงค์ 1.2.4 ข้อได้เปรียบเหนือ Ko ราวครึ่งหนึ่งมาจากการสลับที่น้อยลง และอีกครึ่งมาจากอัตราสูญเสีย throughput และ p5 (ส่วนที่ไม่ใช่ความเสถียร +12.1%) เมื่อให้ Li และ Yuan ใช้ hysteresis เดียวกัน EGAT-MAPPO ยังดีกว่าทั้งสองอย่างมีนัยสำคัญ (บน topology ยืนยัน Li+H +10.7% และ Yuan+H +6.7%; บน ns-3 Yuan+H +16.4%) โดยข้อได้เปรียบเหนือ Yuan+H มาจากคุณภาพของการเลือกช่องและเส้นทาง เพราะทั้งสองวิธีสลับพอๆ กัน การตัดองค์ประกอบชี้ว่า Ko prior ช่วยมากที่สุด และ GRU ไม่ช่วย แบบจำลองหลักจึงตัด GRU ออก ซึ่งยืนยันด้วยโปรโตคอลที่กำหนดไว้ก่อนรัน แบบที่มี GRU ในรอบก่อนเสมอกับ Yuan+H

5.2 ข้อจำกัดของระบบ

5.2.1 สภาพแวดล้อมจำลอง

ผลหลักมาจากสภาพแวดล้อมระดับ flow ที่ใช้แบบจำลองโดเมนการรบกวนแทน CSMA/CA ระดับแพ็กเก็ต แม้ปรับเทียบกับ ns-3 แล้ว ยังคลาดราว 7% และให้ throughput ของ Ko ต่ำกว่า ns-3 ราว 10% ผลเทียบ Ko จึงลดจาก +29.1% ในสภาพแวดล้อมจำลองเหลือ +22–23% บน ns-3 และเมื่อไม่ใช้ RTS/CTS Ko ยังได้ throughput สูงกว่าใน S2 การยืนยันบน ns-3 ครอบคลุม 3 สถานการณ์และ 5 topology ต่อสถานการณ์ ช่วงความเชื่อมั่นเทียบ Yuan+H จึงกว้างและขอบล่างใกล้ 0 และยังไม่ได้ทดสอบบนอุปกรณ์จริง

5.2.2 การตัดสินใจหลังเห็นผลทดสอบ

Hysteresis กติกาเลือก margin และวิธีคำนวณช่วงความเชื่อมั่นถูกเพิ่มหลังเห็นผลทดสอบครั้งแรก แบบจำลอง airtime ถูกเปลี่ยนหลังเห็นผลบน ns-3 และการตัด GRU ถูกเลือกหลังเห็นผลการตัดองค์ประกอบบนชุดทดสอบ margin เลือกบน validation เท่านั้น บันทึกทุกการเปลี่ยนแปลง และการเปลี่ยนเป็นแบบที่ไม่มี GRU ยืนยันด้วยโปรโตคอลที่เขียนไว้

ก่อนรันบน topology 40–59 ที่ไม่เคยใช้ ผลบน topology ชุดนั้นใกล้เคียงชุดทดสอบ (Ko +24.6% เทียบ +26.0%, Yuan+H +6.7% เทียบ +8.5%) ซึ่งชี้ว่าการเลือกนี้ไม่ได้ปรับให้เข้ากับชุดทดสอบมากนัก แต่ผู้อ่านควรทราบว่าโครงสร้างสุดท้ายถูกเลือกหลังเห็นผลบางส่วนแล้ว นอกจากนี้ margin ของแบบที่มี GRU ในรอบแรกถูกเลือกผิดกติกา และแก้ภายหลัง (หัวข้อ 3.4)

5.2.3 น้ำหนักของความเสถียรในคะแนนรวม

ข้อได้เปรียบเหนือ Ko ราวครึ่งหนึ่งมาจากตัวชี้วัดความเสถียร หากผู้ใช้ให้ความสำคัญกับการสลับน้อยกว่านี้ ข้อได้เปรียบจะเล็กลง แม้ยังผ่านเกณฑ์เมื่อปรับน้ำหนัก ±50% และส่วนที่ไม่นับความเสถียรยังเหลือ +12.1%

5.2.4 ส่วนต่างเหนือคู่เทียบที่มี hysteresis

เมื่อ Yuan ได้รับ hysteresis เช่นเดียวกัน EGAT-MAPPO ดีกว่าอย่างมีนัยสำคัญ (+6.7% บน topology ยืนยัน) ซึ่งเกิน 5% แต่ยังไม่ถึงเป้าหมาย 10% ของเกณฑ์ข้อ 1 ช่วงความเชื่อมั่นยังกว้าง (+3.1% ถึง +10.2%) และไม่ผ่านการปรับน้ำหนักที่ระดับ 10% ข้อสรุปว่าสถาปัตยกรรมที่เสนอดีกว่า GAT ของงานเดิมจึงมีหลักฐานสนับสนุน แต่ส่วนต่างยังไม่มาก

5.2.5 ขอบเขตทางสถิติ

คู่เทียบที่เรียนรู้ใช้ 5 ค่าเมล็ดสุ่มการฝึก และการตัดองค์ประกอบใช้เพียง 3 ค่า ช่วงความเชื่อมั่นจึงกว้าง ช่วงความเชื่อมั่นนับเฉพาะความแปรปรวนของค่าเมล็ดสุ่มการฝึก ไม่นับความแปรปรวนจากการสุ่ม topology ซึ่งเป็นเหตุผลที่ยืนยันด้วย topology หลายชุด โดยเฉพาะเทียบ Li ซึ่งแปรปรวนมาก การทดสอบรายสถานการณ์ไม่นับความแปรปรวนของการฝึก จึงอ่านคู่กับช่วงความเชื่อมั่นแบบคู่ค่าเมล็ดสุ่ม

5.2.6 การดัดแปลงคู่เทียบ

Yuan และ Li มาจากงานที่ไม่ได้ออกแบบสำหรับ mesh และไม่มีการเลือกเส้นทาง จึงต้องดัดแปลง action reward และพารามิเตอร์บางส่วน Q-neutral ตีความจากชื่อเพราะไม่มีนิยาม ผลจึงจำกัดเฉพาะ implementation ที่ทดสอบ ไม่ใช่การทำซ้ำบทความต้นฉบับครบถ้วน

5.2.7 การประสานงานขณะใช้งาน

การถอดรหัสช่องแบบลำดับต้องการการประสานหนึ่งรอบต่อการตัดสินใจช่อง เช่นเดียวกับ Ko ยังไม่ได้วัด overhead ของการส่งข้อมูลระหว่างโหนดและเวลาตัดสินใจบนอุปกรณ์จริง

5.2.8 การอ่านผลเทียบ Ko

งานนี้คง Ko ไว้ตามกฎ local cost ของงานต้นฉบับ โดยไม่เพิ่มกลไกที่งานนั้นไม่มี ส่วน Li+H และ Yuan+H เป็นการทดลองเพิ่มเพื่อแยกว่าข้อได้เปรียบของ EGAT+H มาจากตัวแบบจำลองหรือจาก hysteresis ไม่ได้ใช้แทนคู่เทียบตามต้นฉบับ อย่างไรก็ตาม Ko ฉบับที่ดัดแปลงตัดสินใจใหม่ทุก 1 วินาทีตามภาระที่เปลี่ยนตลอด จึงสลับ 616 ครั้งต่อ episode และข้อได้เปรียบเหนือ Ko ราวครึ่งหนึ่งมาจากความเสถียร (ตารางที่ 7) ผลเทียบ Ko จึงควรอ่านคู่กับส่วนที่ไม่นับความเสถียร (+12.1%)

5.3 ปัญหาอุปสรรคและแนวทางแก้ไข

5.3.1 PPO ทำให้นโยบายจาก behaviour cloning แย่ลง

ลักษณะปัญหา นโยบายที่ได้จาก BC ดีกว่า Ko เล็กน้อย แต่เมื่อฝึก PPO ต่อ ผลตอบแทนลดลง (S2: 2769 หลัง BC เหลือ 2708 และ 2623 เมื่อฝึกนานขึ้น) แนวทางแก้ไข เลือก checkpoint ด้วยคะแนนรวมบน validation แทนผลตอบแทนตอนฝึก ใช้ค่าเฉลี่ยเคลื่อนที่ของน้ำหนัก และเก็บนโยบายหลัง BC ไว้เป็นตัวเลือกเสมอ

5.3.2 การสลับบ่อยเกินไป

ลักษณะปัญหา แบบจำลองชนะ Ko ด้าน throughput และอัตราสูญเสีย แต่สลับมากกว่า Li มาก (ราว 200–300 ครั้งต่อ episode) จึงแพ้ Li ในคะแนนรวม แนวทางแก้ไข ใช้ switch hysteresis ขณะใช้งานโดยไม่เปลี่ยนการฝึก และแก้ให้ fallback ประเมิน entropy หลังใส่ hysteresis เพราะ fallback เดิมยังทำให้เกิดการสลับราว 1%

5.3.3 พฤติกรรมแห่ตามกันในการเลือกช่อง

ลักษณะปัญหา ช่องแต่ละช่องสลับป้ายกันได้ เมื่อโหนดเห็นสถานะคล้ายกันจึงเลือกช่องเดียวกัน แนวทางแก้ไข ใช้การถอดรหัสช่องแบบลำดับจากโหนดแม่สู่ลูก และใช้ตัวถอดรหัสเดียวกันกับทุกวิธีที่เรียนรู้เพื่อความเป็นธรรม

5.3.4 ช่วงความเชื่อมั่นที่แคบเกินจริง

ลักษณะปัญหา การตรวจทานอิสระพบว่า bootstrap แบบลำดับชั้นเดิมจับคู่ไฟล์ตามลำดับและไม่นับความแปรปรวนการฝึกของคู่เทียบ ทำให้ช่วงแคบเกินไป แนวทางแก้ไข เปลี่ยนเป็น t-interval จากเมทริกซ์ทุกคู่ค่าเมล็ดสุ่มของทั้งสองวิธี และประเมินยืนยันบน topology ใหม่

5.4 ข้อเสนอแนะในการพัฒนา

5.4.1 ขยายการยืนยันบน ns-3 ให้ครบทุกสถานการณ์และ setting (b) ลดความคลาดของการปรับเทียบที่เหลือ (Ko ต่ำกว่า ns-3 ราว 10%) หรือฝึกบน ns-3 โดยตรง แล้วจึงทดสอบบนอุปกรณ์จริง

5.4.2 เพิ่มส่วนต่างเหนือ Yuan+H ให้ถึง 10% เช่น ฝึก hysteresis ร่วมกับนโยบาย ใส่ต้นทุนการสลับเข้าไปใน critic หรือทดสอบการตัดคุณลักษณะของขอบด้วยโปรโตคอลที่กำหนดไว้ล่วงหน้าแบบเดียวกับ GRU

5.4.3 ทำ hysteresis ให้ปรับตามสถานการณ์หรือเรียนรู้ได้ แทนค่าคงที่ค่าเดียว

5.4.4 เพิ่มจำนวนค่าเมล็ดสุ่มในการตัดองค์ประกอบของแบบที่ไม่มี GRU และเพิ่มจำนวน topology บน ns-3 เพื่อให้ช่วงความเชื่อมั่นเทียบ Yuan+H แคบลง

5.4.5 วัด overhead ของการประสานงานและเวลาตัดสินใจ และขยายไปสู่การควบคุมกำลังส่งร่วมด้วย

เอกสารอ้างอิง

1. TechTarget. (2568). "What is a wireless mesh network (mesh WiFi)?". สืบค้นเมื่อ 1 สิงหาคม 2568, จาก https://www.techtarget.com/searchnetworking/definition/wireless-mesh-network

2. GeeksforGeeks. (2568). "Difference between Fixed and Dynamic Channel Allocations". สืบค้นเมื่อ 1 สิงหาคม 2568, จาก https://www.geeksforgeeks.org/computer-networks/difference-between-fixed-and-dynamic-channel-allocations/

3. V. Lanka. (2567). "Multi-Agent Reinforcement Learning (MARL)". สืบค้นเมื่อ 1 สิงหาคม 2568, จาก https://vinaylanka.medium.com/multi-agent-reinforcement-learning-marl-1d55dfff6439

4. SiamWireless. (2563). "Channel Interference ศัตรูตัวฉกาจของ Wi-Fi". สืบค้นเมื่อ 2 สิงหาคม 2568, จาก https://learnwifi.siamwireless.com/channel-interferences/

5. การเรียนรู้แบบเสริมกำลัง (Reinforcement Learning - RL) และ Q-Learning. ". สืบค้นเมื่อ 2 สิงหาคม 2568 จาก https://www.synopsys.com/glossary/what-is-reinforcement-learning.html

6. Brennan Whitfield (2023) โครงข่ายประสาทแบบกราฟ (Graph Neural Networks - GNN)," สืบค้นเมื่อ 12 ธันวาคม 2568 https://builtin.com/data-science/gnn

7. H. Su, C. Su, F. Ye, and X. Sun. (2024). "Adaptive Channel Assignment for Wireless Mesh Networks Based on Multi-Intelligent Body Reinforcement Learning," *2024 IEEE 7th International Conference on Electronic Information and Communication Technology (ICEICT)*.

8. "Channel Selection for Wi-Fi 7 Multi-Link Operation via Optimistic-Weighted VDN and Parallel Transfer Reinforcement Learning," *arXiv preprint arXiv:2307.05419*, 2023. สืบค้นเมื่อ 3 สิงหาคม 2568, จาก https://arxiv.org/abs/2307.05419

9. C.-L. Kuo, J.-W. Kuo, X.-Z. Chen, and L.-H. Yen. (2022). "Learning-Based Algorithms for Channel Allocations in Wireless Mesh Network," *National Yang Ming Chiao Tung University*.

10. Z. Guo, Z. Chen, P. Liu, J. Luo, X. Yang, and X. Sun, "Multi-Agent Reinforcement Learning-Based Distributed Channel Access for Next Generation Wireless Networks," IEEE Journal on Selected Areas in Communications, vol. 40, no. 5, pp. 1587–1599, 2022, doi: 10.1109/JSAC.2022.3143251.

11. "Multi-Agent Reinforcement Learning for Dynamic Topology Optimization of Mesh Wireless Networks," 2024. สืบค้นเมื่อ 3 สิงหาคม 2568, จาก https://www.researchgate.net/publication/378979579

12. J. Yu, L. Liang, C. Guo, Z. Guo, S. Jin, and G. Y. Li. (2025). "Heterogeneous Multi-Agent Reinforcement Learning for Distributed Channel Access in WLANs," *arXiv preprint arXiv:2412.14218v2*.

13. O. Iacoboaiea, J. Krolikowski, Z. Ben Houidi, and D. Rossi, "Real-Time Channel Management in WLANs: Deep Reinforcement Learning versus Heuristics," in Proc. IFIP Networking Conference, 2021, pp. 1–9, doi: 10.23919/IFIPNetworking52078.2021.9472828.

14. Y. Shao, R. Li, B. Hu, Y. Wu, Z. Zhao, and H. Zhang. (2021). "Graph Attention Network-based Multi-agent Reinforcement Learning for Slicing Resource Management in Dense Cellular Network," arXiv preprint arXiv:2108.05063.

15. X. Du, T. Wang, Q. Feng, C. Ye, T. Tao, Y. Shi, and M. Chen. (2022). "Multi-agent Reinforcement Learning for Dynamic Resource Management in 6G in-X Subnetworks," arXiv preprint arXiv:2205.05036, IEEE Transactions on Wireless Communications.

16. J. Jiang, C. Dun, T. Huang, and Z. Lu. (2020). Graph Convolutional Reinforcement Learning. ICLR 2020. arXiv:1810.09202v5. https://arxiv.org/abs/1810.09202

17. K. N. Ramachandran, E. M. Belding, K. C. Almeroth, and M. M. Buddhikot. (2006). Interference-Aware Channel Assignment in Multi-Radio Wireless Mesh Networks. IEEE INFOCOM. https://sites.cs.ucsb.edu/~almeroth/papers/128.pdf

18. ns-3 Project. ns-3 Manual. https://www.nsnam.org/docs/manual/html/index.html (สืบค้น 16 ตุลาคม 2569).

19. B.-J. Ko, V. Misra, J. Padhye, and D. Rubenstein. (2007). "Distributed Channel Assignment in Multi-Radio 802.11 Mesh Networks," IEEE Wireless Communications and Networking Conference (WCNC), pp. 3978–3983, doi: 10.1109/WCNC.2007.727.

20. S. Yuan, Y. Zhang, T. Ma, Z. Cheng, and D. Guo. (2022). "Graph convolutional reinforcement learning for resource allocation in hybrid overlay–underlay cognitive radio network with network slicing," IET Communications, doi: 10.1049/cmu2.12527.

21. Z. Li, G. Li, Z. Wu, W. Zhang, and A. Bazzi. (2025). "Dynamic Allocation of C-V2X Communication Resources Based on Graph Attention Network and Deep Reinforcement Learning," Sensors, vol. 25, no. 16, 5209.

22. P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio. (2018). "Graph Attention Networks," International Conference on Learning Representations (ICLR).

23. S. Brody, U. Alon, and E. Yahav. (2022). "How Attentive are Graph Attention Networks?," International Conference on Learning Representations (ICLR).

24. J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. (2017). "Proximal Policy Optimization Algorithms," arXiv preprint arXiv:1707.06347.

25. J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel. (2016). "High-Dimensional Continuous Control Using Generalized Advantage Estimation," International Conference on Learning Representations (ICLR).

26. C. Yu, A. Velu, E. Vinitsky, J. Gao, Y. Wang, A. Bayen, and Y. Wu. (2022). "The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games," Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track.

27. A. Raniwala and T. Chiueh. (2005). "Architecture and Algorithms for an IEEE 802.11-Based Multi-Channel Wireless Mesh Network," IEEE INFOCOM.

28. M. Alicherry, R. Bhatia, and L. Li. (2005). "Joint Channel Assignment and Routing for Throughput Optimization in Multi-radio Wireless Mesh Networks," ACM MobiCom.

29. M. Kodialam and T. Nandagopal. (2005). "Characterizing the Capacity Region in Multi-Radio Multi-Channel Wireless Mesh Networks," ACM MobiCom.

30. R. Draves, J. Padhye, and B. Zill. (2004). "Routing in Multi-Radio, Multi-Hop Wireless Mesh Networks," ACM MobiCom.

ประวัติผู้เขียน

ประวัติส่วนตัว

ชื่อ-นามสกุล : นายวิศรุต ไตรยวงศ์ (Mr. Wissarut Taiyawong)

รหัสประจำตัวนักศึกษา : 663380363-7

วันเดือนปีเกิด : 17 มกราคม 2547

อีเมล : wissarut.t@kkumail.com

ประวัติการศึกษา:

ระดับมัธยมศึกษา : โรงเรียนเลิงนกทา

ระดับอุดมศึกษา : หลักสูตรเทคโนโลยีสารสนเทศ สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

แบบฟอร์มการตรวจรายงาน

เอกสารโครงงานฉบับสมบูรณ์ รายวิชา SC364771 โครงงานทางเทคโนโลยี

สารสนเทศ 1

ภาคเรียนที่ 1 ปีการศึกษา 2569

การตรวจสอบจากอาจารย์ที่ปรึกษาโครงงาน

.....

.....

(ลงชื่อ) .....

(ศาสตราจารย์ ดร.จักรชัย โสอินทร์)

วันที่...../...../.....

การตรวจสอบจากกรรมการสอบ

.....

.....

(ลงชื่อ) .....

(ผศ. ดร.สายยัญ สายยศ)

วันที่...../...../.....

การตรวจสอบจากกรรมการสอบ

.....

.....

(ลงชื่อ) .....

(ผศ. ดร.สาธิต กระเวนกิจ)

วันที่...../...../.....

การตรวจสอบจากกรรมการสอบ

.....

.....

(ลงชื่อ) .....

(ผศ. ดร.เพชร อิ่มทองคำ)

วันที่...../...../.....

ข้าพเจ้าขอขอบพระคุณกรรมการสอบทุกท่านที่สละเวลาในการให้คำแนะนำในการจัดทำ เอกสารโครงงานฉบับสมบูรณ์ SC364771 โครงงานทางเทคโนโลยีสารสนเทศ 1 ภาคการศึกษาที่ 1 ปีการศึกษา 2569 ในครั้งนี้ ข้าพเจ้าหวังเป็นอย่างยิ่งว่าจะนำคำแนะนำไปปรับปรุงและพัฒนาผลงานให้ดียิ่งขึ้นไป

ขอแสดงความนับถือ

ผู้จัดทำโครงงาน

(ลงชื่อ) .....

(นายวิศรุต ไตรยวงศ์)

วันที่...../...../.....